

小人口 Lee-Carter 模型的參數分層診斷與估計

——從資料的分布，決定哪些參數可估、該用哪個估計量

第四版 (1006)：依 EDA 佈局與穩健方法架構重組，收斂研究主軸

(林子立) 指導教授：余清祥 教授

國立政治大學統計學系

中華民國 115 年 9 月 26 日

摘要

我國多數鄉鎮市區的單一性別人數不足五萬，Lee-Carter 模型的參數在此規模下出現有方向的偏誤。本文指出三個參數因**不同機制**失效： α_x 源於零格替代與對數轉換、漂移項源於等權重分解對異質變異的敏感、 β_x 則受訊噪比限制而在相變門檻以下不可還原。三者皆可由四項**不需真值的事前診斷**辨認，並分別以偏誤減少、資訊加權與經驗貝氏收縮對應處理。

關鍵詞：小區域估計、Lee-Carter 模型、偏誤診斷、偏誤減少、經驗貝氏收縮、預測區間

一、研究動機與目的

平均餘命 (Life Expectancy) 是衡量地區發展與居民健康的重要指標，可協助政府配置醫療與社會福利資源，也用於保險業的費率計算。其估計須以各年齡的死亡率為基礎，而我國官方編製的生命表只涵蓋全國與縣市層級，並未涉及鄉鎮市區。缺漏的原因不在資料不全，而在樣本規模：368 個鄉鎮市區中有 217 個 (59%) 的單一性別人數在兩萬以下、299 個 (81%) 少於五萬人，此等規模下年齡別死亡率的觀測值震盪劇烈，死亡率較低的青少年年齡組甚至經常沒有死亡人數 (余清祥等 2025)。

人數少所帶來的困難，通常被理解為估計值的震盪，亦即變異數過大。然而 Wang et al. (2018) 與余清祥等 (2021) 指出，Lee-Carter (以下簡稱 LC) 模型的年齡參數在人數減少時還會出現有方向的偏誤，且在人數二十萬以下時特別明顯。這項區別至關重要，因為變異數大可藉由增加資料或重複抽樣察覺，偏誤卻會在所有樣本上朝同一方向偏移，單看估計結果無從發現，也無法靠加寬區間補救。換言之，若小人口的問題確實含有偏誤成分，則補救的第一步不是讓估計更穩定，而是找出偏誤來自模型的哪一個環節。

要追究這個環節，須先問 LC 模型做了什麼假設。Lee and Carter (1992) 以一組簡潔的雙線性結構描述死亡率的時間變化，三十年來成為死亡率推估的標準工具；Basellini et al. (2023) 在其三十週年回顧中，將此一地位歸因於四項優點：結構簡潔，單一時間指標即可導出全年齡的預測；時間指標在多數應用中近乎線性，故可用隨機漫步含漂移項外推；隨機架構可導出機率預測區間；以及純粹外推、不需主觀判斷，因而具有可重複性。這四項優點皆已在國家級人口上反覆驗證，因此本文要檢驗的不是 LC 模型是否正確，而是它在何種條件下適用。

四項優點之中，前三項都建立在同一個技術選擇上，即以奇異值分解 (Singular Value Decomposition，以下簡稱 SVD) 求解。SVD 之所以方便，在於它是封閉解且必然存在，但代價是它等價於無加權的最小平方，因而隱含了同質變異 (Homoscedasticity) 與常態誤差的高斯架構——每一個年齡與年份構成的格子，在目標函數裡被賦予相同的權重。這個代價在國家級人口上幾乎不必付：本文表 1 顯示，全國女性 2001 至 2024 年的 528 個格子中單格死亡數最少亦有 37 人、中位數 1,201 人，零死亡格為 0，各格所攜帶的資訊量雖有差異但同屬可用。但在單一性別不足兩萬的鄉鎮市區，同樣的 528 個格子中平均有 206 格為零，同質變異假設在此不是略有偏差，而是完全失效。

前述主張若僅靠引文支持，只能證明別人也這麼認為，尚不足以說明在本文的資料上確實如此。本文因此設計四項不需要真值、拿到資料即可計算的診斷，直接在資料上檢驗該假設，其內容詳見第參節之二。第一項診斷觀察各年齡單年死亡數的量級，全國女性最低為 5 至 9 歲組的 69 人、最高為 80 至 84 歲組的 10,321 人，相差約 150 倍；落差超過一個數量級，即意味著各格的變異數落差也是同一量級，等權重最小平方因而被誤設。第二項診斷觀察零死亡格落在哪些年齡，模擬五萬人時 1 至 4 歲、5 至 9 歲、10 至 14 歲三組分別有 74%、77%、78% 的年份死亡數為零，而 50 歲以上各組皆為零，可見零格並非散布於全表，而是集中於特定年齡。第三項診斷以對數死亡率沿時間的二階差分估計噪音變異，三個人口規模的點都貼合理論參考線 $1/D$ 且橫跨四個數量級，是異質變異的直接證據，也量化了它的嚴重程度。第四項診斷在奇異值的碎石圖上加一條純噪音所能產生的上緣，最大奇異值穿出這條線，年齡參數才可能還原，實測全國女性的比值為 6.53，模擬二十萬為 1.19，模擬五萬僅 0.43。此處另有一個反直覺之處值得指出：最大奇異值的絕對值完全不能判讀，全國女性的最大奇異值為 3.44，而模擬五萬人的最大奇異值反而是 4.23，小人口的奇異值被噪音灌水，必須與上緣相比才有意義。

假設不成立本身仍不足以支持更換方法，畢竟許多假設都不完全成立而方法照常好用；必須進一步證明失效有代價，而且代價的類型決定了補救的方式。本文的 T-ratio 診斷（第參節之三）顯示，三個參數的病因並不相同。年齡水準參數 α_x 是偏誤主導，人數一萬時 5 至 9 歲組的 $|T|$ 高達 56.4，隨人口增大而系統性下降，人數二十萬以上後全面落入 ± 2 之內。年齡敏感度參數 β_x 在小樣本下則是變異數主導，人數二十萬以下時 $|T|$ 不及 0.25，須至五十萬以上變異數收斂後偏誤才顯現，人數一百萬時 70 至 74 歲組的 $|T|$ 為 1.87；小樣本時 T 接近零並非估得好，而是變異數大到把偏誤掩蓋。時間參數的漂移項性質與 α_x 同為偏誤主導，但來源並不相同：本文第伍節的階梯式分解中，對真值加入對稱高斯噪音後再做 SVD 的變體完全不涉及對數轉換、亦不存在零格，卻使 α_x 的最大偏誤由 0.743 降至 0.021，而漂移項的偏誤仍達 0.347，甚至略大於標準 LC 的 0.305。

三項診斷合起來給出本文的核心判斷： α_x 的偏誤來自對數轉換與零格替代，漂移項的偏誤來自等權重分解對異質變異的敏感， β_x 在小樣本下則受訊噪比限制，在相變門檻以下根本不可還原。三者的補救方式互不相同，偏誤必須找出來源加以校正，變異數才可藉收縮處理，而不可還原的部分則應誠實地不予估計。更值得注意的是，這三種失效都在原始資料中留有可事前辨認的徵兆：第二項診斷指出 α_x 的偏誤會落在哪些年齡，第一與第三項診斷指出加權失衡的嚴重程度，第四項診斷指出 β_x 是否可還原。因此在

配適任何模型之前，就能判斷哪些參數可估、該用哪個估計量，這即是本文的主張。取得鄉鎮市區資料的使用者既無真值亦無從進行模擬，可事前計算的指標因而比一個固定的人口數門檻實用得多，也才能解釋為何同為五萬人，有的地區可估而有的不可。

依上述主張，本文提出四個依序遞進的研究問題。其一，四項事前診斷能否在配適模型之前，正確指出哪些參數可估、偏誤會落在哪些年齡。其二，三個參數的失效機制是否確實不同，對數轉換是否為偏誤的唯一來源。其三，依機制選用的估計量各能改善多少，改善的位置是否與診斷所指一致，以及在什麼條件下失效。其四，小人口的預測區間誤差來自何處，文獻長期主張的「LC 模型預測區間過窄」在此是否成立。

本文編排如下。第貳節定義記號與模型、回顧文獻，並於其中說明本研究的目的與所欲瞭解的四項議題；第參節說明研究資料、四項事前診斷、偏誤診斷與二因子模擬設計，回應問題一；第肆節以 Rabbi and Mazzucco (2021) 的還原與懲罰式估計為例，論證在高斯架構內修補的限度；第伍節以階梯式分解辨識偏誤的來源，並比較各估計量的改善幅度與適用條件，回應問題二與問題三；第陸節處理區間推論，回應問題四；第柒節歸納適用邊界並提出結論。

二、文獻回顧

本節先定義全文使用的記號與模型（第一小節），回顧其兩條估計路線與小人口情境的既有對策（第二、三小節），據以說明本研究的目的（第四小節），最後回顧與該目的直接相關的文獻（第五小節）。

一、記號與 Lee-Carter 模型

為免混淆，本文先統一以下記號。以 $x = 1, \dots, A$ 表示年齡組的索引、 $t = 1, \dots, T$ 表示年份的索引，本文的主要設定為 $A = 22$ 個五齡組、 $T = 24$ 年。純量以細體小寫表示， $D_{x,t}$ 為第 x 個年齡組在第 t 年的死亡數、 $E_{x,t}$ 為對應的暴露數（人年）、 $m_{x,t} = D_{x,t}/E_{x,t}$ 為中央死亡率。向量以粗體小寫表示並一律視為行向量，

$$\boldsymbol{\alpha} = (\alpha_1, \dots, \alpha_A)^\top, \quad \boldsymbol{\beta} = (\beta_1, \dots, \beta_A)^\top, \quad \boldsymbol{\kappa} = (\kappa_1, \dots, \kappa_T)^\top,$$

亦即附下標的 α_x 、 β_x 、 κ_t 表示對應向量的第 x （或第 t ）個分量，不附下標的粗體符號則表示整個向量；以 $\mathbf{1}_A$ 表示長度 A 的全一向量， $\mathbf{1}_A/A$ 即各分量皆為 $1/A$ 的均勻向量。矩陣以粗體大寫表示， $\mathbf{D} = (D_{x,t})$ 、 $\mathbf{E} = (E_{x,t})$ 、 $\mathbf{M} = (m_{x,t})$ 。估計值於符號上方加帽，真值於必要時加上標 true；向量的 L_1 與 L_2 norm 分別記為 $\|\cdot\|_1$ 與 $\|\cdot\|_2$ 。

Lee and Carter (1992) 的模型設定為

$$\log m_{x,t} = \alpha_x + \beta_x \kappa_t + \varepsilon_{x,t}, \quad (1)$$

其中 α_x 為第 x 個年齡組的平均死亡水準、 β_x 為該年齡組對時間趨勢的敏感度、 κ_t 為第 t 年的死亡率時間指標。以矩陣寫成 $\log \mathbf{M} = \boldsymbol{\alpha} \mathbf{1}_T^\top + \boldsymbol{\beta} \boldsymbol{\kappa}^\top + \boldsymbol{\varepsilon}$ ，可見模型的秩為一——每

一年的整條對數死亡率曲線，皆由單一純量 κ_t 沿固定方向 β 平移而得。此一結構在後文解釋數個現象時會反覆用到。

式 (1) 對 (β, κ) 的尺度與平移並不唯一，須施加識別條件，本文沿用原始設定

$$\mathbf{1}_A^\top \beta = \sum_{x=1}^A \beta_x = 1, \quad \mathbf{1}_T^\top \kappa = \sum_{t=1}^T \kappa_t = 0. \quad (2)$$

式 (2) 的第一式在第四節扮演決定性的角色，它使「朝零收縮」的懲罰項退化為常數，因而完全失效。在卜瓦松架構下模型改寫為 $D_{x,t} \sim \text{Poisson}(E_{x,t} \exp(\alpha_x + \beta_x \kappa_t))$ ，以最大概似法估計，此時 $\varepsilon_{x,t}$ 不再需要同質變異的假設。

本文另須用到壽命差異 $e_0^\dagger$ ，它描述死亡年齡分布的離散程度，定義為 $e_0^\dagger = \int_0^\infty d(a) e(a) da$ ，其中 $d(a)$ 為死亡年齡分布的密度、 $e(a)$ 為 a 歲的平均餘命，直觀而言即「每一位死者平均損失的餘命年數」。相對於零歲平均餘命 e_0 描述死亡年齡分布的平均， $e_0^\dagger$ 描述其變異，兩者互補。本文採用簡略生命表 (Chiang) 的離散近似計算。

二、兩條估計路線：高斯與卜瓦松

LC 模型的估計自始即與奇異值分解綁在一起。Lee and Carter (1992) 並未主張對數死亡率的誤差同質，卻選擇了一個隱含此假設的解法，並在估計之後以第二階段調整補救，即重新求解時間參數使配適的總死亡數等於觀測值。Basellini et al. (2023) 指出，此後三十年間高斯路線的主要進展，幾乎都是在改變第二階段「對齊什麼」。Lee and Miller (2001) 發現對齊總死亡數不足以修正零歲平均餘命的偏誤，改為直接對齊該量；然而以單一總量為約束仍嫌寬鬆，Booth et al. (2002) 因而改以卜瓦松離差逐年齡對齊死亡數；循此思路，Rabbi and Mazzucco (2021) 進一步主張平均餘命只描述死亡年齡分布的位置，改為對齊描述其離散程度的壽命差異。這是一條逐步精緻化的線，每一步都在修正前一步「對齊的量不夠貼近真正關心的量」。

然而這條線在準確度上已無太多可爭取的空間。Booth et al. (2005) 系統比較各種替代調整後發現，它們對預測準確度的影響可以忽略，LC 模型準確度較差的主因實為初始值誤差問題與配適期長度。換言之，問題並不在於第二階段對齊了哪個量，而在第一階段的估計本身——若第一階段的偏誤是結構性的，事後調整單一的時間參數並無法移除它。

卜瓦松路線因此從源頭更換架構。Brouhns et al. (2002) 將死亡數視為卜瓦松分配的觀測值、以暴露數為抵補項 (Offset)，以最大概似法估計參數；由於誤差直接作用於計數上，且配適總死亡數依照模型假設即等於觀測值，第二階段調整不再必要。Currie (2013) 進一步將其納入廣義線性模型 (Generalized Linear Model) 架構，Currie (2011) 則專門處理高齡資料品質不佳時的推估。惟文獻在比較兩條路線時多半止於「卜瓦松較佳」，未說明較佳之處何在。這是因為兩條路線的差異其實綁了三件事：是否對資料取對數、是否加權、以及分配假設本身。三者同時更換，就無從判斷改善由何者貢獻，也無從判斷在什麼情況下不必更換。

三、小人口的失效機制與既有對策

上一小節所述的困難在國家級人口上大多可以忍受，到了小人口才成為主要問題，原因是三個彼此加乘的機制。第一是零死亡格，當某年齡組的期望死亡數低於 1 時觀測值經常為 0，而 $\log 0$ 無定義，實務上多以固定值（如 0.5）替代，此舉會系統性地墊高該格的死亡率；關鍵在於此一機制只作用於零格所在的年齡，因而在資料上留下明確的位置訊息。第二是對數轉換的加權失衡，Basellini et al. (2023) 指出取對數等於給低死亡率較大權重、給高死亡率較小權重，而高死亡率出現在高齡、該處人口又相對龐大，因此以死亡數計的誤差被放大；Wilmoth (1993) 因而建議改以死亡數為權重的加權最小平方。這一點同時解釋了上一小節的現象——高斯路線之所以需要第二階段調整，正是因為第一階段的權重配置與資訊量不符。第三是過度離散 (Overdispersion)，死亡計數普遍較卜瓦松分配更為分散，高齡尤然；Renshaw and Haberman (2003) 提出過度離散卜瓦松擬概似，Li et al. (2009) 以 gamma 脆弱性導出年齡別過度離散參數並顯示預測區間較卜瓦松 LC 增寬 18% 至 180%，Djeundje and Currie (2010) 另在平滑架構下直接處理離散過度的計數資料。

面對這些機制，最直觀的對策是增加樣本數。Li and Lee (2005) 的共同 LC 模型以一組死亡改善趨勢相近的母體為參考，Wang et al. (2018) 建議合併目標母體過去 10 至 20 年的歷史資料，Jarner and Kryger (2011) 的 SAINT 模型以大母體為錨定，Wiśniowski et al. (2015) 與 Cairns et al. (2011) 則以貝氏方法達成類似效果。這些作法形式各異，卻共用同一個關鍵假設，即參考母體與目標母體的死亡型態相近。該假設在臺灣並不安全，縣市間平均餘命的最大差距即超過 10 歲 (Yue et al. 2019)，鄰近地區的社經與人口組成差異甚大。

假設不可靠時，另一條路是不借外部資訊而直接平滑目標母體自身的資料。Yue et al. (2019) 將修勻 (Graduation) 與死亡率模型結合，先以部分標準化死亡比 (Lee 2003) 或 Whittaker 比值修勻小區域的死亡率，再套用 LC 或 Li-Lee 模型，並以電腦模擬比較七種死亡率情境，發現型態相近時部分標準化死亡比表現最佳、型態差異較大時則以 Whittaker 比值較為穩健。修勻的對象亦可是參數而非死亡率本身，其技術基礎為 Eilers and Marx (1996) 的懲罰式 B 樣條，經 Currie et al. (2004) 推廣至年齡與時間的二維平滑；Basellini et al. (2023) 將此類作法分為估計前、估計中、估計後三類，Hyndman and Ullah (2007) 與 Rabbi and Mazzuco (2021) 屬估計前修勻率，Delwarde et al. (2007) 在配適演算法中加入懲罰年齡參數不規則性的項、Currie (2013) 擴充至同時懲罰兩組年齡參數，二者屬估計中修勻參數，Renshaw and Haberman (2003) 以三次 B 樣條修勻已估出的年齡參數，則屬估計後修勻參數。

修勻雖不需外部母體，卻引入了另一個問題：平滑的強度須由資料決定，而選擇的準則未必瞄準真正關心的量。Delwarde et al. (2007) 以交叉驗證選取平滑參數，衡量的是曲面對觀測值的預測誤差；Rabbi and Mazzuco (2021) 則直接以對觀測值的誤差比較各種修勻法。兩者瞄準的都是配適誤差而非參數的估計誤差，本文第肆節將顯示後者在臺灣資料上甚至會傾向選擇「不修勻」，因為修勻依定義必然增加對觀測值的誤差。

四、本研究的目的

前述對策的共同特徵，是在承認估計有誤差之後設法使它變小，而未追問誤差的性質。小樣本問題並非無人研究：Chen et al. (2017) 以參數式拔靴法系統地探討人口規模對最大概似估計量有限樣本分布的影響，涵蓋參數之間的相依結構與概似比檢定的檢定力；國內的 Wang et al. (2018) 與 Yue et al. (2019, 2021) 則以 t -ratio 為判準，結論為人口不超過 50,000 時 LC 模型須謹慎使用，保守而言建議至少一百萬。惟這些研究回答的是「估計有多不準」，而非「估計是否系統性偏移、偏移來自哪一個環節」。更值得注意的是，Chen et al. (2017) 的對象是 M7 模型、估計方式自始即為卜瓦松最大概似，而本文第伍節將顯示卜瓦松最大概似估計量的漂移項幾乎無偏誤，真正產生系統性偏誤的是 LC 模型預設的奇異值分解；以卜瓦松最大概似為起點的研究設計，恰好看不到本文關切的現象。

本研究因此把問題換一個方向提出：與其追求更小的誤差，不如先辨識誤差的來源，再依來源選用對應的估計量。若三個參數的誤差來自不同的環節，則補救方式亦應不同，而混用單一方法必然在某些參數上失效。更進一步，若這些環節在原始資料中留有徵兆，則判斷所需的量便可在配適任何模型之前計算——這對實務尤其重要，因為取得鄉鎮市區資料的使用者既無真值亦無從進行模擬，一個可在自己資料上計算的指標，遠比一個固定的人口數門檻有用。

依此方向，本文對既有文獻有四項議題想要瞭解。議題一是小樣本研究多針對變異數，對奇異值分解本身的偏誤著墨較少，仍有補充空間的是該偏誤的來源及其對預測區間的影響。議題二是修勻壓低預測區間寬度的現象已被 Basellini et al. (2023) 在討論節明確提出並點名五齡組，卻未提供任何量化證據。議題三即前一小節所述的選參準則錯置。議題四是時間參數在小人口的行為尚未被檢驗，此點由 Yue et al. (2019) 於結論中明白指出，該研究僅設定年齡參數的各種情境而未考慮時間參數，然而漂移項直接乘上預測期長度進入平均餘命，其偏誤對長期預測的影響遠大於年齡參數。

五、參數的可估性與補救

承上，若要依誤差的來源選用估計量，須先回答三個層次的問題：在給定的資料量下參數能否估計、偏誤該如何處理、變異數該如何處理。本小節依此順序回顧。

(一) 可估性的界限

前述文獻處理的都是如何估得更好，但更前置的問題是能不能估。尖峰隨機矩陣 (Spiked Random Matrix) 理論對此有明確的答案。Baik et al. (2005) 首先在樣本共變異矩陣上證明了相變的存在，Benaych-Georges and Nadakuditi (2012) 則給出矩形矩陣的對應結果：設 $n \times m$ 的噪音矩陣加上秩一訊號 θuv^T 、 $c = n/m$ ，該文第 3.1 節式 (9) 與式 (10) 指出，當 $\theta > c^{1/4}$ 時估計出的奇異向量與真值有正的漸近內積且該內積有閉式，當 $\theta \leq c^{1/4}$ 時內積漸近為零。這個結果的性質與前述文獻截然不同：門檻以下不是估得比較差，而是估出來的方向與隨機向量無法區分，此時任何估計量的改良都無從發揮，正確的作法是不予估計。

相變之所以發生，可由 Zhang et al. (2022) 的 HeteroPCA 看得更清楚。該文指出當各列的噪音變異數不同時，樣本 Gram 矩陣的期望為 $\Sigma_0 + \text{diag}(\sigma_1^2, \dots, \sigma_p^2)$ ，亦即對角線被噪音變異數系統性灌水而非對角線不受影響，故異質變異越嚴重、主特徵向量偏得越多，補救因而須作用於奇異向量。Gavish and Donoho (2017) 給出的最適奇異值收縮則提供了一個反例：它在矩陣重建的意義下最適，卻對 β_x 完全無作用，因為它作用在奇異值上而非奇異向量。

(二) 偏誤減少

偏誤主導的參數無法靠加寬區間或增加重複處理，必須在估計的環節上動手。Firth (1993) 的懲罰概似是小樣本偏誤減少的標準方法，其設計目標正是移除最大概似估計量的 $O(1/n)$ 偏誤，做法是在得分方程中加入修正項，等價於對概似乘上 Jeffreys 事前分配 $|I(\theta)|^{1/2}$ 。該方法在 logistic 迴歸中最著名的效果，是解決完全分離 (Separation) 造成的估計值發散，因為 Jeffreys 懲罰使概似在參數空間的邊界上不再遞增，解必定存在且有限。這一點恰好對上前一小節的第一個機制：卜瓦松模型在零計數時有完全分離的對應物，概似在 $\alpha_x \rightarrow -\infty$ 時仍遞增，最大概似估計量根本不存在。

與之相對的是事後校正，即先估再修，如參數式拔靴法的 $\tilde{\theta} = 2\hat{\theta} - \bar{\theta}^*$ 。兩者的差別在於 Firth 在估計當下就無偏而非估完再修，因而不會放大變異數；本文第伍節將以模擬比較兩者。

(三) 收縮估計

變異數主導的參數則適用收縮，其核心思想是接受少量偏誤以換取變異數大幅下降，使總均方誤差下降。James and Stein (1961) 證明當待估參數的維度足夠高時，朝某一目標收縮的有偏估計量在總均方誤差上可優於不偏估計量，此為整條脈絡的理論根據。Hoerl and Kennard (1970) 的 Ridge 迴歸是第一個具體實作，以 L_2 懲罰縮減係數；Tibshirani (1996) 的 LASSO 改用 L_1 懲罰，因其近端算子為軟閾值而能把係數精確壓至收縮目標，同時達成收縮與變數選擇；惟 LASSO 在變數高度相關時傾向任意只保留其一，Zou and Hastie (2005) 的 Elastic Net 因而混合兩種懲罰，以群組效應使相關的一組變數傾向被一同保留或剔除；LASSO 對大係數亦施加同等收縮而產生偏誤，Zou (2006) 的自適應 LASSO、Meinshausen (2007) 的鬆弛 LASSO 與 Zhang (2010) 的 MCP 相繼提出修正。演算法方面，Friedman et al. (2010) 的座標下降法已成為標準作法，Tseng (2001) 與 Lee et al. (2014) 分別提供區塊座標下降與近端牛頓法的收斂理論。

此一脈絡進入死亡率模型的時間不算晚，但懲罰的對象與本文不同：Delwarde et al. (2007) 與 Currie (2013) 懲罰的皆為年齡參數的差分，即粗糙度，目的在取得平滑的年齡曲線，本文則依指導方向懲罰年齡參數本身，目的在辨識哪些年齡組顯著偏離參考水準。

更重要的是，這一整條脈絡有一個共同的操作負擔：懲罰強度必須由資料選出，而第三小節所述的選參準則錯置問題於此同樣無法迴避。此處值得引入一條字面上與本文問題完全吻合、卻尚未被死亡率文獻援用的脈絡——小區域估計。Fay and Herriot (1979)

的模型以受限最大概似 (Restricted Maximum Likelihood, 以下簡稱 REML) 估計變異成分, 並給出依訊噪比自動決定收縮強度的最佳線性無偏預測, Rao and Molina (2015) 為該領域的標準參考。其相對於懲罰式估計的優勢在於沒有調校參數, 收縮強度由估計出的變異成分決定, 不需交叉驗證或格點搜尋, 選參準則錯置的問題因而不復存在。

(四) 判斷準則

上述三者各有適用的情境, 因此還需要一組準則, 用以判斷手上的資料落在哪一情境。既有研究給出的準則多為人口數門檻, 如 Wang et al. (2018) 的 50,000 與一百萬, 惟門檻由模擬得出, 未必適用於年齡結構或配適期長度不同的資料。本文第參節因此把前述三個層次各自翻譯成一個可由資料直接計算的量: 零死亡格的分布對應偏誤減少的需求, 死亡數的跨年齡落差與噪音變異的跨度對應加權的需求, 而最大奇異值與純噪音上緣的比值則對應可估性的界限。四者皆不需要真值, 前三者甚至不需要配適模型。

三、 研究資料與診斷

一、資料來源與分布特性

本文資料取自人類死亡率資料庫 (Human Mortality Database, 以下簡稱 HMD) 的臺灣序列, 涵蓋 1970 至 2024 年的分年齡死亡數與暴露數 (人年)。原始檔為單齡組, 本文依官方簡易生命表的慣例聚合為 0、1 至 4、5 至 9、依此類推至 95 至 99, 並將 100 歲以上併為開放組, 共 22 個年齡組; 併組的理由是 110 歲以上於 1970 至 2009 年的暴露數為零。主要分析對象為女性 2001 至 2024 年, 共 $22 \times 24 = 528$ 格。

表 1 主分析資料的分布特性 (女性 2001~2024 年)

項目	數值
資料維度	22 齡組 $\times$ 24 年 = 528 格
單格死亡數: 最小 / 中位數 / 最大	37 / 1,201 / 16,184
零死亡格數	0
2024 年暴露數: 最小 / 中位數 / 合計	2,883 / 552,075 / 11,871,065
死亡數最少者 (全期合計)	5-9 歲組 1,812 人
死亡數最多者 (單年中位數)	80-84 歲組 10,321 人

表 1 有兩點須特別說明。其一, 全國層級的資料並無零死亡格, 單格死亡數最少亦有 37 人, 因此本文在全國資料上所見的問題不能直接歸因於資料稀疏。其二, 死亡數在年齡上的分布極不均勻, 5 至 9 歲組的單年死亡數中位數為 69 人, 而 80 至 84 歲組達 10,321 人, 相差約 150 倍; 此一落差正是後續討論的關鍵, 因為同一組資料之中不同年齡的有效樣本數相差兩個數量級, 估計精度自不可同日而語。至於鄉鎮市區層級則完全不同, 以單一性別兩萬人的規模推算, 528 格中平均有 206 格無死亡發生, 約四成的格子不含任何資訊。

二、四項事前診斷

第壹節已概述四項診斷的內容，本小節說明其計算方式與判讀門檻。四者的共同特點是不需要真值：前三項為純粹的探索性資料分析，第四項僅需一次成本不到一秒的預備配適。程式見 R/core/eda_diagnostics.R。

第一項診斷取各年齡組單年死亡數的中位數，以對數刻度繪於年齡上，須看兩件事，即曲線的最低點是否進入個位數，以及最高與最低相差幾個數量級。第二項診斷取各年齡組死亡數為零的年份比例，回答的不是「有多少零」而是「零在哪裡」。第三項診斷以對數死亡率沿時間的二階差分估計噪音變異，二階差分消去線性趨勢，而 $\text{Var}(\Delta^2 X) = 6\sigma^2$ ，故 $\widehat{\text{Var}} = \text{Var}(\Delta^2 \log \hat{m})/6$ ，以此對各年齡的期望死亡數作雙對數散布圖並加上理論參考線 $1/D$ 。第四項診斷取中心化對數死亡率矩陣的奇異值譜，並加上純噪音所能產生的上緣；依第二之五 小節， $n \times m$ 噪音矩陣的最大奇異值收斂至 $\sigma\sqrt{T}(1 + \sqrt{c})$ ， $c = A/T$ ，而該文式 (9) 另有一個便於操作的性質——在相變門檻上，觀測到的最大奇異值恰好等於這條上緣，故判讀規則即為最大奇異值是否穿出虛線。




圖 1 四項事前診斷。橫向比較全國女性實際資料與兩組模擬小人口（以全國配適為真值， $D_{x,t} \sim \text{Poisson}(Nw_x m_{x,t}^{\text{true}})$ ）。①②③ 為純粹的探索性分析；④ 的噪音上緣需一次預備配適以估計 σ 。

表 2 四項診斷的數值摘要

診斷項目	全國女性	模擬 20 萬	模擬 5 萬
① 最小單年死亡數中位數	69	1	0
① 死亡數的跨年齡落差（倍）	150	298	72
② 零死亡格比例（%）	0.0	4.4	18.8
② 零格最集中的年齡組	—	10–14	1–4
③ 噪音變異的跨度（數量級）	2.0	2.3	1.7
④ 最大奇異值 s_1	3.44	4.96	4.23
④ 純噪音的上緣	0.53	4.17	9.80
④ s_1 / 上緣	6.53	1.19	0.43
判讀	訊號充分	邊緣	不可還原

第四項診斷需要噪音的尺度 σ ，其估法會直接影響結論，故須特別說明。本文比較三種事前可得的估法，並以已知結論（人數二十萬以上可還原、五萬為邊緣、一萬不可還原）檢驗。由觀測死亡數估計者可用但偏保守，若採用宜將門檻放寬至 1.2；由一次

Firth 卜瓦松預備配適取得 $\hat{\mu}$ 並令 $\sigma = \sqrt{1/\hat{\mu}}$ 者最為可靠，本文採用此法；而由二階差分估計者不可使用，人數一萬時會誤判為可還原，因為四成零格被 0.5 墊平之後，二階差分反映的是替代值的假象而非真實噪音。

表 3 診斷④的判讀門檻與對應建議

s_1 / 上緣	判讀	建議
> 2	訊號充分	各方法差異小，SVD 亦可
$1.2 \sim 2$	可還原	卜瓦松或加權 SVD ($w = \hat{\mu}$)，加經驗貝氏收縮
$0.6 \sim 1.2$	邊緣	方法選擇的效益最大；卜瓦松／Firth 加收縮
< 0.6	不可還原	不要以 SVD 估 β_x ； α_x 仍可靠 Firth 取得

表 3 最後一列的措辭須加以限定。相變門檻界定的是未正則化的秩一分解能還原多少，並非所有估計量的上界；本文第伍節將顯示，人數五萬（比值 0.43）時標準 LC 的 $\hat{\beta}_x$ 與真值相關僅 0.040，確實與隨機方向無異，但加上經驗貝氏收縮後可達 0.542。因此該格應讀為「不要以 SVD 估計」，而非「無論如何都不能估計」。

綜合本文第伍節的結果，第一項診斷可給出兩個操作門檻：最小單年死亡數中位數低於 5 時，Firth 為必要而非選配，低於 20 時建議使用；死亡數的跨年齡落差超過一個數量級時，等權重 SVD 已被誤設，應改用卜瓦松或以 $\hat{\mu}$ 加權的 SVD。全國女性的 69 與 150 倍分別落在「安全」與「須加權」兩側，這說明即使在國家級資料上加權仍屬必要，只是零格的問題不存在。

三、參數估計的偏誤診斷

前一小節的診斷不需要真值，代價是只能指出假設失效與可能的後果，無法量化偏誤的大小。本小節以電腦模擬補上這一層：令女性 2001 至 2024 年的 LC 配適為真值， $E_{x,t} = N \cdot w_{x,t}$ 、 $D_{x,t} \sim \text{Poisson}(E_{x,t} m_{x,t}^{\text{true}})$ ， N 取 10^4 至 5×10^6 共九個水準，各重複 1,000 次。圖示規格比照 Wang et al. (2018) 第 354 至 355 頁。

除偏誤與標準誤外，本文另計算 T-ratio

$$T_x = \frac{\text{Bias}(\hat{\theta}_x)}{\text{s.e.}(\hat{\theta}_x)}, \quad (3)$$

其意義為系統性偏誤相對於單次估計之抽樣標準差的倍數。 $|T_x| > 2$ 表示該年齡的偏誤已超過抽樣變異的兩倍，亦即偏誤而非變異數才是該處的主要誤差來源，反之 $|T_x|$ 很小則表示變異數主導。此一指標可直接回答「究竟該先處理偏誤還是先處理變異數」，因而決定了後續應選用哪一類方法。




圖 2 $\hat{\alpha}_x$ 與 $\hat{\beta}_x$ 的 T-ratio。虛線為 ± 2 參考線；超出者表示偏誤大於兩倍抽樣標準差。

表 4 各人口規模下 $|T| > 2$ 的年齡組數與極值（共 22 組）

N	α 之 $ T > 2$ 組數	β 之 $ T > 2$ 組數	α 之 $\max T $ (年齡)	β 之 $\max T $ (年齡)
10^4	9	0	56.4 (5-9)	0.22 (1-4)
2×10^4	7	0	31.0 (5-9)	0.21 (5-9)
5×10^4	3	0	9.4 (5-9)	0.09 (1-4)
10^5	1	0	2.6 (5-9)	0.05 (10-14)
2×10^5	0	0	1.2 (15-19)	0.05 (85-89)
5×10^5	0	0	1.3 (5-9)	1.47 (80-84)
10^6	0	0	1.1 (5-9)	1.87 (70-74)
2×10^6	0	0	0.8 (5-9)	1.32 (70-74)
5×10^6	0	0	0.5 (5-9)	0.76 (70-74)

$\hat{\alpha}_x$ 的 T-ratio 在小樣本時極為可觀，且集中於幼年組。人數一萬時 5 至 9 歲組達 56.4，二萬時為 31.0，五萬時仍有 9.4，至十萬降為 2.6，二十萬以上後始全面落入 ± 2 之內。此一型態與 Wang et al. (2018) 所述「 α_x 的偏誤最為顯著」一致，而偏誤集中於幼年組的原因可由表 1 直接讀出：5 至 9 歲組的單年死亡數中位數僅 69 人，在人數一萬的情境下期望死亡數不足 1，零格與對數轉換的影響於此最為劇烈。值得注意的是，這個位置不需要模擬就能指出——前一小節的第二項診斷所畫的正是同一件事的事前版本，兩者指向同一組年齡。

$\hat{\beta}_x$ 的情形與 α_x 截然不同。其 T-ratio 在小樣本時極小，人數二十萬以下時最大值不及 0.25，隨人口增大反而上升至一百萬時的 1.87（70 至 74 歲組），其後又下降至五百萬時的 0.76，呈現明顯的非單調型態。此一型態不可誤讀：小樣本時 $|T|$ 接近零並不代表 $\hat{\beta}_x$ 估得好，而是其抽樣標準差大到使偏誤相形之下微不足道，人數一萬時 $\hat{\beta}_x$ 與真值的相關中位數為 -0.24 ，估計值實質上已無資訊。待人數增至五十萬以上、變異數收斂之後，原先被掩蓋的偏誤才浮現為顯著，此時偏誤方成為誤差的主要成分。

本小節的結論是三個參數不應以同一種方法處理。 α_x 在小樣本下偏誤主導，須以校正偏誤的手段處理； β_x 在小樣本下變異數主導，收縮類方法於此有其正當性，惟人數

五十萬以上後偏誤轉為主要成分，此時固定強度的收縮反而有害，此即第肆節所觀察到「固定比例的懲罰在人數三十萬以上後反受其害」的成因；至於漂移項，其偏誤的來源與 α_x 並不相同，須待第伍節的階梯式分解方能辨識。

四、配適期長度與人口規模的二因子設計

前兩小節皆以固定的配適期（24 年）變動人口規模，但實務上鄉鎮市區可用的歷史資料長度未必相同，而配適期同時影響兩件事：可用的資訊量，以及 β_x 不隨時間變動這項假設的合理性。在實際資料上配適期一拉長、可用資料量必然同時增加，兩者無法分離，模擬的價值正在於可以固定其一、只變動其二。

三種情境在結果上的形貌截然不同，因而可據以區辨。若只有資訊量重要，則配適期與人口規模可互相替代，任何組合只要乘積相近、表現就應相近；若 β_x 的穩定性才是主要限制，則拉長配適期反而會因納入過時的年齡型態而使表現變差；若配適期另有獨立於資訊量的作用，則增加人口無法補償配適期的不足，表現會在某個長度以下出現無法以人口規模跨越的下限。

本小節因此以二因子設計分離兩者：以女性 1970 至 2024 年（55 年）的配適為真值，對每個組合模擬最近 T 年的死亡數並重新估計， T 取 10、15、20、30、40、55 年， N 取兩萬、五萬、二十萬與一百萬，各重複 100 次。

評估指標改用 $\hat{\beta}_x$ 與真值的相關係數而非誤差平方和，原因是在配適期與人口規模都很小時，時間參數的變化範圍不足以識別 β_x ，估計值會完全退化為均勻向量 $\mathbf{1}/A$ ；此時誤差平方和恰為 $\|\mathbf{1}/A - \beta^{\text{true}}\|^2 = 0.0070$ ，反而小於配適期稍長但估計值劇烈震盪時的數值，若只看誤差平方和會誤判為「短配適期較佳」。

表 5 $\hat{\beta}_x$ 與真值的相關係數中位數（未懲罰，重複 100 次）

T (年)	$N = 2 \times 10^4$	$N = 5 \times 10^4$	$N = 2 \times 10^5$	$N = 10^6$
10	0.247	0.156	0.170	0.120
15	0.188	0.191	0.226	0.465
20	0.178	0.217	0.407	0.760
30	0.323	0.593	0.785	0.952
40	0.508	0.725	0.899	0.977
55	0.746	0.874	0.966	0.991

表 6 退化率： $\hat{\beta}_x$ 完全塌陷為 $\mathbf{1}/A$ 的比例

T (年)	$N = 2 \times 10^4$	$N = 5 \times 10^4$	$N = 2 \times 10^5$	$N = 10^6$
10	0.81	0.27	0	0
15	0.53	0.04	0	0
20	0.22	0	0	0
≥ 30	0	0	0	0

結果支持第三種情境。配適期十年時，即使人口達一百萬，相關係數仍僅 0.120，而配適期五十五年時人口僅兩萬亦達 0.746；配適期二十年以下時，沒有任何人口規模能

達到 0.8 的水準。換言之，配適期的作用不只是提供更多資料，增加人口無法補償它的不足。表 6 的退化率則說明了短配適期失效的形式：配適期十年、人口兩萬時有 81% 的模擬中 $\hat{\beta}_x$ 完全塌陷為均勻向量，亦即估計程序根本沒有從資料中取得任何年齡型態的資訊。

此一結果可由第二之五 小節的相變理論解釋。訊號強度隨配適期成長的速度遠快於門檻，而噪音尺度僅隨人口規模的平方根下降，因此等準確度曲線在兩個因子上並不對稱——這也說明了為何本文第四項診斷的比值必須逐筆資料計算，而不能以單一的人口數門檻代替。

四、 在高斯架構內修補的限度

第貳節指出，高斯路線三十年來的進展多在改變第二階段「對齊什麼」，而 Booth et al. (2005) 的評估顯示這條線在準確度上已無太多可爭取的空間。本節以兩個具體的例子檢驗這項判斷：一是文獻中最新且最精緻的第二階段調整，即 Rabbi and Mazzuco (2021) 的修勻搭配壽命差異調整；二是直接在配適過程中加入懲罰項的作法。前者代表「在既有架構內把調整做得更細」，後者代表「在既有架構內加入外部資訊」。兩者的共同結論是，只要第一階段仍以等權重的秩一分解為基礎，可改善的幅度便有其上限。

一、修勻與壽命差異調整的界限

Rabbi and Mazzuco (2021) 的方法由兩部分構成，本文以 $LCe^\dagger$ 簡稱之。第一部分是在配適 LC 模型之前，先對觀測的對數死亡率曲面做二維修勻：以年齡與時間兩個方向的二階差分作為粗糙度的度量，並以 L_1 而非 L_2 為損失，故目標函數為分段線性，等價於 $\tau = 0.5$ 的分位數迴歸而須以線性規劃求解。第二部分是在估計之後重新求解時間參數，使配適的壽命差異等於觀測值，取代 Lee and Carter (1992) 對齊總死亡數的作法。在女性 2001 至 2024 年的資料上，該方法確實如原文所述具有較小的配適誤差，表 7 顯示 L_1 修勻的平均絕對誤差為 0.0413，低於一維與二維樣條的 0.0538 與 0.0759。

表 7 三種修勻法的比較（女性 2001~2024 年）

修勻法	MAE	MSE	年齡方向粗糙度	時間方向粗糙度
觀測值	—	—	0.0204	0.0981
一維樣條 (L_2 , 年齡)	0.0538	0.0218	0.0140	0.0908
二維樣條 (L_2)	0.0759	0.0247	0.0137	0.0025
LASSO (L_1)	0.0413	0.0047	0.0179	0.0012

然而把比較擴充為性別與配適起始年構成的十二格面板之後，此一優勢並不穩固。表 8 顯示 $LCe^\dagger$ 僅在五格取得最佳的樣本外平均絕對誤差，其餘七格由 Lee-Miller 奪冠，而且在長配適期之下無一例外。此一型態與 Booth et al. (2005) 的結論一致：替代調整方式的效益不僅有限，且會隨可用資訊增加而消失。

表 8 各面板格的樣本外 MAE ($h = 5$); 粗體為該格最佳

起始年	LCe [†]	MLCe [†]	LM	LC	起始年	LCe [†]	MLCe [†]	LM	LC
女 2001	.0962	.0962	.1080	.1194	男 1981	.1323	—	.1099	.1454
女 1991	.0992	.0988	.1064	.1197	男 1971	.1124	—	.1078	.1353
女 1981	.1194	.1202	.1057	.1163	總 2001	.0862	.0841	.0967	.1141
女 1971	.1172	.1152	.1061	.1300	總 1991	.0945	.0905	.0956	.1266
男 2001	.0965	.0942	.1062	.1232	總 1981	.1080	—	.0950	.1268
男 1991	.1243	—	.1090	.1436	總 1971	.1005	—	.0935	.1227

更值得注意的是預測區間。表 9 顯示 LCe[†] 的 2050 年零歲平均餘命預測區間是六種方法中最寬者。修勻的直觀效果是壓低歷史變異、使區間變窄，此處卻反其道而行，原因在於壽命差異調整重新求解時間參數之後，其年際變動反而增大。這一點與 Basellini et al. (2023) 所提出、卻未量化的疑慮方向相反，本文第陸節將以變體分解說明兩者何以並存。

表 9 2050 年女性零歲平均餘命的預測與 80% 預測區間

方法	e_0 (2050)	80% 預測區間	區間寬度
LC	87.99	[86.10, 89.69]	3.591
LCP	88.02	[86.53, 89.40]	2.875
LM	87.86	[86.25, 89.34]	3.090
BMS	87.95	[86.45, 89.34]	2.895
LCe [†]	87.61	[85.51, 89.49]	3.977
MLCe [†]	87.47	[85.45, 89.29]	3.842

此處另有一項與本文議題三直接相關的觀察。原文以各修勻法對觀測值的誤差作為選擇準則，而修勻依定義必然增加對觀測值的誤差，因此在臺灣資料上，該準則必然傾向選擇「不修勻」。換言之，這個準則衡量的是配適誤差而非參數的估計誤差，兩者在小人口下並不同向。

二、懲罰式估計的結構性限制

另一條在高斯架構內改善估計的途徑，是把懲罰項直接加在年齡參數上。此處先指出一項識別條件所導致的結構性限制。LC 模型以 $\sum_x \beta_x = 1$ 識別，若取收縮目標為零向量（即一般 LASSO 的預設），則在 $\hat{\beta}_x$ 全為正（人口規模較大時必然如此）的情形下 $\sum_x |\beta_x| \equiv 1$ 為常數，懲罰項不影響最適解，估計值完全不動。表 10 顯示 λ 由 0 加到 10^6 ，估計值的變動量始終在機器精度之內。

表 10 收縮目標的選擇 (女性 2001~2024 年)

λ	$\beta_0 = 0$		$\beta_0 = \mathbf{1}/A$	
	$\max \hat{\beta} - \hat{\beta}^{\text{unpen}} $	自由參數	$\max \hat{\beta} - \hat{\beta}^{\text{unpen}} $	自由參數
0	—	22	—	22
10^2	9.0×10^{-17}	22	0.0041	19
10^4	1.5×10^{-16}	22	0.0612	6
10^6	2.1×10^{-15}	22	0.0612	0

本文因此改取均勻向量 $\mathbf{1}/A$ 為收縮目標。此一選擇有三項優點： $\sum_x (\beta_x - \beta_{0x}) = 0$ 使懲罰項有效；具明確的人口學意義，即「各年齡以相同速度改善」，且當 $\lambda \rightarrow \infty$ 時解收斂至 $\mathbf{1}/A$ ；而 LASSO 的稀疏性在此回答的是「哪些年齡組的改善速度顯著偏離平均」，正是指導方向所期待的解釋效果。

收縮目標修正之後，懲罰確實有效。表 11 與表 12 顯示人數五萬時 β 的均方誤差可降低 94%，符合第參節「小樣本下 β_x 變異數主導」的診斷。但同一組結果亦顯示了限制所在：變異數隨人口規模下降的速度快於偏誤，兩者在人數三十萬附近交叉，此後固定比例的懲罰反而使均方誤差上升。這與第參節 T-ratio 的非單調型態是同一件事的兩種表現——收縮的正當性僅存在於變異數主導的區間，而該區間的上界可由診斷事前判定。

表 11 β 的偏誤—變異數分解 (LASSO, 重複 100 次)

N	$\lambda/\lambda_{\max}$	偏誤 ²	變異數	MSE
50,000	0 (未懲罰)	0.00239	0.15980	0.16058
	0.10	0.00648	0.00512	0.01155
	0.20	0.00854	0.00158	0.01010
	1.00	0.01066	2.8×10^{-6}	0.01066
200,000	0 (未懲罰)	0.00024	0.01691	0.01698
	0.01	0.00015	0.01062	0.01066
	0.03	0.00147	0.00560	0.00702
	0.10	0.00707	0.00102	0.00808

表 12 變異數與 MSE 隨暴露數的變化 (重複 100 次)

N	未懲罰		LASSO ($\lambda/\lambda_{\max} = 0.1$)	
	變異數	MSE	變異數	MSE
20,000	4.3912	4.3860	0.0223	0.0286
50,000	0.2139	0.2148	0.0060	0.0119
100,000	0.0526	0.0530	0.0021	0.0089
200,000	0.0184	0.0184	0.0009	0.0081
500,000	0.0066	0.0066	0.0003	0.0078
1,000,000	0.0030	0.0030	0.0001	0.0077
log-log 斜率	-1.77		-1.27	

若純就均方誤差而論，三種懲罰之中勝出的是 Ridge 而非 LASSO（表 13），亦即稀疏性並非此處正確的先驗。LASSO 的價值在於可解釋性：它以約兩成的均方誤差，換取「哪些年齡組顯著偏離平均改善速度」的明確答案。自適應 LASSO、鬆弛 LASSO 與 MCP 三種變體則全數輸給單純的 Ridge，其細節列於附錄。

表 13 三種懲罰的比較（ $N = 20$ 萬，重複 100 次，各取其最適 λ ）

懲罰	a	最適 $\lambda/\lambda_{\max}$	偏誤 ²	變異數	MSE	β 相關中位數
未懲罰	—	0	0.00024	0.01691	0.01698	0.711
LASSO	1.0	0.030	0.00147	0.00560	0.00702	0.703
Elastic Net	0.5	0.030	0.00158	0.00534	0.00687	0.705
Ridge	0.0	0.003	0.00270	0.00311	0.00578	0.721

三、小結

本節的兩個例子指向同一件事。修勻與壽命差異調整把第二階段的對齊做得更細，懲罰式估計則在第一階段加入外部資訊，兩者都能在特定條件下改善估計，但改善的幅度與適用範圍都受限於一個共同的前提：第一階段仍是等權重的秩一分解。懲罰式估計的限制尤其明白，其有效區間的上界（人數三十萬）正是偏誤取代變異數成為主要誤差來源的位置，而偏誤本身並未被處理。

因此，下一節不再在此架構內尋求改良，而是回頭辨識偏誤究竟來自哪一個環節，再依機制選用對應的估計量。

五、偏誤的來源與估計方法的選擇

第參節已指出 α_x 與漂移項是偏誤主導，第肆節則顯示在高斯架構內修補無法移除這項偏誤。本節先辨識偏誤來自哪一個環節，再依機制選用估計量並量化其改善幅度與適用條件。

一、偏誤來源的階梯式分解

第貳節指出，高斯與卜瓦松兩條路線的差異綁了三件事：是否對資料取對數、是否加權、以及分配假設本身。要判斷偏誤由何者造成，須把三者拆開，每次只移除一個因素。本文據此構造五個估計量所成的階梯（表 14），以女性 2001 至 2024 年的配適為真值、人數五萬、重複 400 次。由於少數模擬會發散（單次平方誤差可達中位數的 10^6 倍），統計量一律採中位數而非平均數。

表 14 偏誤分解的估計量階梯

代號	估計量	仍存在的因素
A	標準 LC: 對 $\log(\max(D, 0.5)/E)$ 做 SVD	(1)(2)(3)(4)
B	A + Jensen 一階校正 $+1/(2D)$	(1)(3)(4)
C	以 D 為權重的加權 SVD (Wilmoth 1993)	(1)(2)(4)
D	卜瓦松最大概似 (不取對數)	(4)
E	高斯對照: 對真值 $\log m$ 加均值為零、變異數與卜瓦松相當的噪音後做 SVD	僅 (4)

表 15 偏誤來源的階梯分解 (重複 400 次, 穩健統計)

N	估計量	α 偏誤 (中位數)	SSE(β) 中位數	β 相關	漂移項偏誤
5×10^4	A 標準 LC	-0.0371	0.409	-0.07	0.305
	B + Jensen 校正	0.0115	0.236	-0.36	0.199
	C 加權 SVD	0.0889	0.088	0.03	0.141
	D 卜瓦松 MLE	-0.0107	0.071	0.41	0.011
	E 高斯對照	0.0008	0.921	0.27	0.347
2×10^5	A 標準 LC	-0.0214	0.061	0.51	0.175
	B + Jensen 校正	0.0028	0.048	0.21	0.155
	C 加權 SVD	0.0322	0.016	0.51	0.071
	D 卜瓦松 MLE	-0.0008	0.015	0.67	0.004
	E 高斯對照	0.0008	0.149	0.47	0.259

變體 E 是回答本問題的關鍵。它對真值的對數死亡率加入均值為零、變異數與卜瓦松相當的高斯噪音後再做 SVD, 因而完全不涉及對數轉換、不存在零格, 噪音亦對稱而無重尾。結果 α_x 的最大偏誤由標準 LC 的 0.743 降至 0.021, 幾乎歸零; 但漂移項的偏誤仍達 0.347, 甚至略大於標準 LC 的 0.305。換言之, 若偏誤僅來自對數轉換, 變體 E 的漂移項亦應改善, 事實並非如此, 因此對數轉換不是唯一的來源。

漂移項的偏誤來自何處, 可由變體 C 得到答案。該變體仍在對數尺度上操作、仍有零格, 只是把等權重改為以死亡數加權, 漂移項偏誤即由 0.305 降至 0.141、 β 的平方誤差和由 0.409 降至 0.088。加權所改變的只有各格在目標函數中的相對重要性, 因此漂移項的偏誤來自等權重分解對異質變異的敏感——用第貳節第四小節的語言說, 即主奇異向量被噪音旋轉。此一機制與對數無關, 這也是變體 E 的偏誤未能改善的原因。

本小節可歸納為一句話: 取對數傷 α_x , 不加權傷漂移項。兩者是獨立的病, 也需要獨立的藥。

二、五種估計量的比較

依上述診斷, 本小節比較五種估計量, 每一種各處理一個機制 (表 16)。模擬設定同前, 重複 100 次、種子固定。

表 16 五種估計量各自處理哪一個機制

代號	估計量	取對數	加權	收縮
A	標準 LC (現行作法)	是	無	無
B	加權 SVD ($w = \hat{\mu}$)	是	$\hat{\mu}$	無
C	卜瓦松最大概似	否	內建	無
D	Firth 偏誤減少	否	內建	無
E	Firth + Fay-Herriot 收縮	否	內建	有

變體 B 須特別說明。Wilmoth (1993) 原式以觀測死亡數為權重，但此舉使權重與反應變數相關——該格恰好觀測到較多死亡時同時被賦予較大的權重， $\hat{\alpha}$ 因而被系統性推高。表 15 的變體 C 即依原式實作，其 α 偏誤為 +0.0889，是五個變體中唯一明顯為正者。本小節改以配適期望死亡數 $\hat{\mu}_{x,t}$ 為權重並隨迭代更新，此為一行程式碼的修改。

表 17 五種估計量的比較 (重複 100 次，取中位數)。 α 欄為逐年齡偏誤中位數的絕對值，分別取其中位數與最大值； $SSE(\beta)$ 為相對平方誤差和； $cor(\beta)$ 為與真值的中心化相關。

N	估計量	α 中位	α 最大	$SSE(\beta)$	$cor(\beta)$	漂移偏誤
10^4 零格 206/528	A 標準 LC	0.1612	2.3309	7.916	-0.074	0.3436
	B 加權 SVD	0.1128	2.3315	3.319	0.068	0.2436
	C 卜瓦松 MLE	0.0495	13.0317	15.525	0.118	0.1612
	D Firth	0.0248	0.4267	17.797	0.116	0.2237
	E Firth + FH	0.0248	0.4267	4.984	0.125	0.2237
5×10^4 零格 100/528	A 標準 LC	0.0611	0.8658	4.449	0.037	0.3339
	B 加權 SVD	0.0553	0.8723	0.904	0.201	0.1223
	C 卜瓦松 MLE	0.0073	0.2260	1.756	0.365	0.0492
	D Firth	0.0088	0.0680	1.410	0.397	0.0485
	E Firth + FH	0.0088	0.0680	0.143	0.542	0.0485
2×10^5 零格 29/528	A 標準 LC	0.0231	0.1846	1.400	0.379	0.2117
	B 加權 SVD	0.0234	0.1397	0.305	0.527	0.0393
	C 卜瓦松 MLE	0.0018	0.0361	0.346	0.596	0.0267
	D Firth	0.0025	0.0398	0.333	0.605	0.0262
	E Firth + FH	0.0025	0.0398	0.095	0.697	0.0262

α_x 的結果最為明確。人數五萬時，逐年齡的最大偏誤由標準 LC 的 0.866 降至 Firth 的 0.068，改善 12.7 倍。人數一萬那一組更值得注意：該規模下 528 格中有 206 格為零，標準 LC 與卜瓦松最大概似的偏誤方向相反而且都極大。標準 LC 把 5 至 9 歲組的 α 推高 +2.33，因為零格以 0.5 替代而該處的期望死亡數遠低於 0.5，等於人為墊高該格的死亡率；卜瓦松最大概似則把它推低 -13.03，因為零計數下概似在 $\alpha \rightarrow -\infty$ 時仍遞增，估計量根本不存在，此即第貳節所述完全分離現象在卜瓦松上的對應物；Firth 為 +0.43，相對標準 LC 改善 5.5 倍、相對卜瓦松 30 倍。這一組數字修正了一個常見的簡化說法：「改用卜瓦松路線比較好」在零格眾多時並不成立，單以逐年齡最大偏誤衡量，此時卜瓦松反而比 SVD 更糟，正確的陳述是「卜瓦松加 Firth 最好」。

變體 B 與 A 的對照則是本節最乾淨的一項證據。人數五萬時把權重加入高斯路線

之後，漂移項偏誤由 0.3339 降至 0.1223、 β 的平方誤差和由 4.449 降至 0.904，但 α 的最大偏誤紋風不動，0.8658 對 0.8723。因為加權完全沒有觸及零格與對數轉換。這與前一小節變體 E 的結果恰成互補的一對——一個不取對數但不加權， α 歸零而漂移項最差；一個取對數但加權，漂移項改善而 α 不動——兩者合起來確立了本文的核心分工。

β_x 則須分規模討論。人數一萬時五種估計量的相關係數全在 0.125 以下，與第四項診斷的「不可還原」判讀一致，此規模下應誠實地不予估計。人數五萬起情況改變，標準 LC 的 0.037 確實與隨機方向無異，但 Firth 加上 Fay-Herriot 收縮後可達 0.542，平方誤差和由 4.449 降至 0.143；人數二十萬時則由 0.379 提升至 0.697。收縮之所以有效，正因為第參節已指出 β_x 在此規模是變異數主導，而 Fay-Herriot 的收縮強度由估計出的變異成分決定，沒有調校參數，因而避開了第肆節所指的選參準則錯置問題。

三、改善的位置與事前診斷的對應

若第參節的主張成立，則估計量的改善應出現在診斷所指的年齡，而非散布全表。圖 3 以淺色柱表示各年齡的零死亡格比例、以折線表示各估計量的 α 偏誤，兩者的峰值完全重疊。




圖 3 逐年齡的 α 偏誤 (折線) 與零死亡格比例 (淺色柱，相對高度)。標準 LC 的偏誤峰值與零格所在的年齡完全重疊；卜瓦松在同處往反方向發散；Firth 則近乎水平。

若以逐年齡的零格比例與 $|\alpha|$ 偏誤計算 Spearman 相關，標準 LC 在人數一萬、五萬、二十萬三個規模下分別為 0.863、0.881、0.740。亦即第三之三小節圖中 T-ratio 的尖峰位置，不需要真值、不需要一千次模擬，看第二項診斷即可事前指出。

此處有一項判讀上的陷阱須明說。Firth 的 Spearman 相關在人數一萬時為 0.915，並不低於標準 LC，但這不表示 Firth 沒有改善——Spearman 相關對尺度不變，衡量的是「偏誤落在哪些年齡」而非「偏誤有多大」，Firth 改善的是同一批年齡上的量級。值得注意的是 Firth 的相關隨人口增大而下降，三個規模依序為 0.915、0.789、0.484，顯示其殘餘偏誤在大人口下已不再由零格驅動。

四、古典穩健方法為何在此失效

上述診斷同時界定了哪些方法不適用於本問題。古典穩健統計處理的是污染，即絕大多數觀測來自模型而少數來自別處，其設計目標是讓少數離群值無法主導估計。但前一小節的變體 E 已排除此一情境：該變體的噪音對稱、期望為零、無重尾，沒有任何離群值，卻仍產生 0.347 的漂移項偏誤。既然沒有東西可截，截尾自然無從發揮。

本文以最大截尾概似與最小截尾平方兩種代表性方法驗證此一預期（表 18），並同時納入 HeteroPCA 作為對照。

表 18 穩健估計的兩側：截尾類與 HeteroPCA（重複 100 次，取中位數）

N	估計量	α 中位	α 最大	$SSE(\beta)$	$\text{cor}(\beta)$	漂移偏誤
5×10^4 零格 102/528	標準 LC	0.0700	0.8658	3.538	0.040	0.3144
	卜瓦松 MLE	0.0119	0.2053	2.166	0.298	0.0232
	Firth	0.0060	0.0882	1.742	0.310	0.0180
	HeteroPCA	0.0700	0.8658	1.992	0.093	0.2247
	HeteroPCA + FH	0.0700	0.8658	0.355	0.273	0.2247
	MTL (保留 90%)	0.0276	0.4712	4.082	0.222	0.0192
	LTS (保留 90%)	0.0190	0.7871	4.311	0.041	0.3055
2×10^5 零格 29/528	標準 LC	0.0148	0.1671	1.341	0.390	0.2124
	卜瓦松 MLE	0.0034	0.0367	0.313	0.615	0.0015
	Firth	0.0013	0.0271	0.299	0.619	0.0016
	HeteroPCA	0.0148	0.1671	0.632	0.416	0.1100
	HeteroPCA + FH	0.0148	0.1671	0.155	0.551	0.1100
	MTL (保留 90%)	0.0066	0.0836	0.377	0.603	0.0016
	LTS (保留 90%)	0.0081	0.2239	1.243	0.389	0.2124

結果有三。其一，沒有任何截尾變體勝過未截尾的卜瓦松最大概似。其二，最小截尾平方完全不處理漂移項的偏誤，人數五萬時為 0.3055、標準 LC 為 0.3144，人數二十萬時兩者皆為 0.2124，數值幾乎相同；它確實改善了 α （因為截掉了零格替代所造成的極端對數值），但 β 的相關係數 0.041 與標準 LC 的 0.040 無異。這正是本小節開頭所預期的：截尾與「異質變異噪音旋轉主奇異向量」這個機制正交。其三，最大截尾概似的表現接近卜瓦松最大概似，因為它本就建立在卜瓦松概似之上，但每一項指標都略差。

截尾失效的機制可由逐年齡的保留率看得更清楚。表 19 於人數五百萬、模型正確、無零格亦無離群值的條件下統計各年齡被保留的比例；若截尾是中性的，各年齡的保留率應大致相同。

表 19 截尾規則的逐年齡保留率 ($N = 5 \times 10^6$, 模型正確、無零格、無離群值)

年齡組	β_x 真值	MTL 保留率	LTS 保留率	單年期望死亡數
0	0.0496	0.98	0.88	111
1-4	0.1066	0.99	0.36	28
5-9	0.0697	1.00	0.52	24
10-14	0.0442	1.00	0.60	25
15-19	0.0578	0.99	0.71	50
40-44	0.0328	0.95	1.00	485
70-74	0.0669	0.82	1.00	4,619
80-84	0.0439	0.71	1.00	6,487
85-89	0.0319	0.71	1.00	7,233
100+	0.0078	0.94	1.00	503

最小截尾平方丟掉了 64% 的 1 至 4 歲組與 48% 的 5 至 9 歲組，而這兩組正是 β_x 最大的兩個年齡 (0.1066 與 0.0697)。機制很直接：在對數尺度上， $|\beta_x \kappa_t|$ 最大的年齡也是偏離秩一結構時殘差最大的年齡，因此「最不合模型」的格恰好是「攜帶最多趨勢訊號」的格；截掉它們之後剩餘的格更貼合秩一結構，但 β 的形狀資訊已被丟棄。最大截尾概似則偏好丟掉 80 至 94 歲，保留率 0.71 至 0.72，那是死亡數最多的年齡 (單年 5,328 至 7,233 人)，因為卜瓦松逐格對數概似的絕對值隨計數量級成長，高計數格的概似貢獻本就較低，截尾規則因而系統性地移除資訊量最大的格。兩種截尾規則丟掉的是不同的格，但都是錯的格。

HeteroPCA 的結果則從反面支持同一診斷。它直接針對 Gram 矩陣對角線被噪音變異數灌水的問題，人數五萬時使 β 的平方誤差和由 3.538 降至 1.992、人數二十萬時由 1.341 降至 0.632，再加上 Fay-Herriot 收縮後分別為 0.355 與 0.155；但它的 α 偏誤與標準 LC 完全相同 (0.0700 與 0.0148)，因為 α 的偏誤來自對數轉換與零格替代，與 Gram 矩陣的對角線無關。這個分工與本節第一小節的結論完全吻合，可作為診斷正確性的旁證。

須說明的是，表 18 與表 17 為兩次獨立的模擬，亂數種子不同，故同一估計量的數值略有出入，例如標準 LC 在人數五萬的 α 偏誤中位數為 0.0700 與 0.0611、 β 的平方誤差和為 3.538 與 4.449。此一差距反映重複 100 次時蒙地卡羅誤差的量級， α 偏誤約一成、平方誤差和約兩成，可作為解讀各表數值時的精度參考。

五、穩健損失的作用範圍：中位數的崩潰點

前一小節顯示截尾類方法在此完全失效，但這並不表示所有以穩健為設計目標的工具都無用。截尾與檢查函數的差別在於前者丟棄觀測、後者只是改變損失的形狀，因此值得分開檢驗。本小節即以分位數 LC 進行此一檢驗，並藉此劃出穩健損失在本問題上的作用範圍。

檢驗的依據是一項可事先寫下的預測。把平方損失換成檢查函數 $\rho_\tau(u) = u\{\tau -$

$\mathbf{1}(u < 0)$ 之後，目標函數成為

$$\min_{\alpha, \beta, \kappa} \sum_{x,t} w_{x,t} \rho_{\tau}(\log m_{x,t} - \alpha_x - \beta_x \kappa_t), \quad (4)$$

而關鍵在於：若取 $w_{x,t} \equiv 1$ ，則檢查函數是**等權重**的——一格 16,184 死與一格 37 死在目標函數裡貢獻相同的權重，與 SVD 的等權重最小平方同構。據此可預測，中位數 ($\tau = 0.5$) 對「小計數取對數造成的左尾扭曲」穩健，因而應改善 α_x ；但它並未處理加權失衡，因而不應改善漂移項。本文以式 (4) 的兩個版本檢驗之，變體 F 取 $w_{x,t} \equiv 1$ ，變體 G 取 $w_{x,t} = \hat{\mu}_{x,t}$ 。

求解採交替最小化。固定 κ 時，各年齡各自是一條簡單的分位數迴歸，以線性規劃求解；固定 α 與 β 時，各年份各自是一維的加權分位數問題， $\tau = 0.5$ 時解為 $\{(\log m_{x,t} - \alpha_x)/\beta_x\}$ 以 $w_{x,t}|\beta_x|$ 為權重的加權中位數。兩步皆為各自區塊的全域最小，故目標函數單調不增，實際收斂約需六至七次迭代。模擬的亂數種子與表 17 完全相同，故兩表可逐格對照；表 20 中標準 LC 一列即為內部對照，其數值與表 17 相同。

表 20 分位數 Lee-Carter (重複 100 次，種子與表 17 相同)

N	估計量	α 中位	α 最大	SSE(β)	cor(β)	漂移偏誤
10^4	A 標準 LC (對照)	0.1612	2.3309	7.916	-0.074	0.3436
	F 中位數 LC	0.0965	2.3020	10.864	-0.077	0.3671
	G 加權中位數 LC	0.0733	2.3020	4.950	0.023	0.2986
5×10^4	A 標準 LC	0.0611	0.8658	4.449	0.037	0.3339
	F 中位數 LC	0.0284	0.6925	5.349	0.013	0.3110
	G 加權中位數 LC	0.0187	0.6925	1.548	0.084	0.1591
2×10^5	A 標準 LC	0.0231	0.1846	1.400	0.379	0.2117
	F 中位數 LC	0.0048	0.1780	1.055	0.443	0.0696
	G 加權中位數 LC	0.0032	0.1818	0.536	0.435	0.0428

預測的前半段成立。變體 F 在三個規模下都使 α 的偏誤中位數約降一半至數倍，人數二十萬時由 0.0231 降至 0.0048，改善近五倍。預測的後半段則只在小人口成立：人數一萬時 F 的漂移項偏誤為 0.3671，反而略大於標準 LC 的 0.3436；人數五萬時為 0.3110 對 0.3339，改善僅 7%。但到了人數二十萬，F 的漂移項偏誤降至 0.0696，是標準 LC 的三分之一——這已不能說是「沒有改善」。

表 21 零死亡格比例隨人口規模的變化（各年齡，重複 200 次）

年齡組	β_x 真值	$N = 10^4$	$N = 5 \times 10^4$	$N = 2 \times 10^5$
0	0.0496	0.79	0.33	0.01
1-4	0.1066	0.93	0.74	0.30
5-9	0.0697	0.95	0.77	0.35
10-14	0.0442	0.95	0.77	0.36
15-19	0.0578	0.90	0.60	0.14
50-54	0.0290	0.14	0.00	0.00
80-84	0.0439	0.00	0.00	0.00

此一看似不一致的型態，可由表 21 得到完整的解釋，而解釋的關鍵正是中位數的崩潰點。零格替代所造成的扭曲並非隨機散布，而是集中於幼年組，且其比例隨人口規模急遽變動：人數二十萬時 1 至 4 歲組有 30% 的年份死亡數為零，人數五萬時升至 74%，人數一萬時達 93%。中位數的崩潰點為 50%，亦即當被扭曲的觀測超過半數時，中位數本身就是一個被扭曲的值，穩健性不復存在。

三個規模的結果恰好落在崩潰點的兩側，因而可逐一對應。人數二十萬時扭曲比例為 30% 至 36%，低於崩潰點，中位數得以忽略它們，5 至 9 歲組的 α 偏誤由 -0.0330 降至 -0.0006 ，幾乎完全消除；由於幼年組正是 β_x 最大的年齡（1 至 4 歲組為 0.1066），其對時間參數的影響最大，修好它們連帶使漂移項偏誤下降三分之二。人數五萬時扭曲比例升至 74% 至 77%，已超過崩潰點，同一年齡的 α 偏誤僅由 0.8658 降至 0.6925，改善兩成；人數一萬時比例達 93% 至 95%，改善僅 1%，漂移項甚至變差。

這個結果為第貳節之四所述的論點提供了直接的量化證據。本研究的問題不是古典意義的污染——在鄉鎮市區的規模下，被扭曲的並非少數幾格，而是幼年組的絕大多數格。以污染為設計目標的工具在此失效，不是因為它們不夠好，而是因為污染比例已超出其設計的適用範圍。換言之，穩健損失的作用範圍有一個可以事前計算的上界，即診斷②所量出的零格比例是否超過 50%。

加權的必要性則在三個規模下都成立。變體 G 與 F 的差別只在權重，而 G 的漂移項偏誤在人數五萬時為 0.1591、F 為 0.3110，相差近一倍； β 的平方誤差和亦由 5.349 降至 1.548。這與第一小節「取對數傷 α_x 、不加權傷漂移項」的分工完全一致，並顯示檢查函數與資訊加權是可以疊加的兩件事。

最後須指出兩項限制。其一，變體 F 的 β 平方誤差和在人數一萬與五萬時反而大於標準 LC（10.864 對 7.916、5.349 對 4.449），亦即檢查函數在改善 α 的同時損害了 β ，這是穩健損失的效率代價在本問題上的具體形式。其二，即使是表現最佳的變體 G，其 α 最大偏誤在人數五萬時仍為 0.6925，遠高於 Firth 的 0.0680（表 17）。兩者的差別在於處理的層次：檢查函數改變的是損失的形狀，但零格替代所產生的錯誤資訊仍在資料裡；Firth 則根本不取對數、不需替代零格，從源頭避免了該筆錯誤資訊。就本文的問題而言，換分配假設仍優於換損失函數。

六、估計後的校正

前述作法都在估計當下處理偏誤，另一條路是先估再修。最直接的作法是參數式拔靴法的偏誤校正 $\tilde{\theta} = 2\hat{\theta} - \bar{\theta}^*$ ，其中 $\bar{\theta}^*$ 為自配適模型重抽所得估計值的平均。

表 22 參數式拔靴法偏誤校正的效果（重複 150 次，每次拔靴 60 次）

指標	$N = 5 \times 10^4$		$N = 2 \times 10^5$	
	未校正	校正後	未校正	校正後
β 的偏誤平方和	0.0708	0.0202	0.0092	0.0054
β 的 SSE 中位數	0.4628	0.5682	0.0583	0.0428
漂移項偏誤	0.308	0.291	0.178	0.137

結果是混合的。校正確實降低了偏誤， β 的偏誤平方和在兩個規模下分別下降 71% 與 41%，顯示參數式拔靴確實能偵測到相當部分的偏誤。但校正的代價是放大變異數： $2\hat{\theta} - \bar{\theta}^*$ 這一線性組合的變異數約為原估計值的兩倍，因此人數五萬時總誤差反而上升，須至人數二十萬變異數較小後淨效果才轉為正向。

這一結果修正了本研究早期的論述。先前主張「拔靴法繞著已經偏掉的配適值重抽，偵測不到自己的偏誤」，語氣過強——它確實偵測到了七成，但校正本身會放大變異數，故在變異數本已過大的小樣本下並不划算。實務建議因此是：人數二十萬以上時可考慮拔靴偏誤校正，更小的規模則應優先改用在估計當下即無偏的方法，而非事後校正。

六、 區間推論

點估計的準確與區間的有效是兩個不同的性質，而且可能衝突——第肆節即顯示修勻改善了點估計卻使區間變寬。本節因此獨立檢驗區間，回應問題四。

一、來源分解：四個層層疊加的變體

區間的寬度與位置由多個誤差來源共同決定，單一組數字無法辨識各成分的貢獻。本文因此設計四個層層疊加的變體，每次只加入一個誤差來源。變體 O 假設參數全部已知，區間只反映時間參數未來的創新項，此為任何方法都無法低於的理論下限，其涵蓋率應接近名目的 0.80，可作為整個實驗的效度檢查。變體 P 以估計出的時間參數與其變異數代入，即現行實務作法，P 與 O 的差距即為以估計值取代真值所須付出的權衡。變體 B 在 P 之上以拔靴法納入參數估計的不確定性，若參數不確定性是區間失效的主因，B 應明顯優於 P。變體 S 則在 B 之上先行修勻，專門檢驗 Basellini et al. (2023) 所提出而未量化的疑慮。預測期取 $h = 10$ 、名目水準 80%，目標為涵蓋真模型在觀測的時間參數路徑下的零歲平均餘命。

閱讀時須同時看兩個指標。平均寬度反映區間的大小，涵蓋率反映區間是否擺對位置，兩者必須合看——寬度過大而涵蓋率仍低，即代表位置錯誤而非寬度不足。

表 23 預測區間寬度與涵蓋率的來源分解 (名目 80%)

N	變體	平均寬度	涵蓋率
50,000	O 僅未來創新項 (不可約下限)	1.743	0.85
	P 插入式 (現行作法)	5.401	0.38
	B P + 參數不確定性	6.166	0.24
	S 修勻 + B	1.683	0.66
200,000	O	1.720	0.82
	P	5.651	0.82
	S	1.515	0.63
1,000,000	O	1.738	0.77
	P	4.390	0.94
	S	1.194	0.45
11,900,000	O	1.723	0.87
	P	1.950	0.88
	S	0.529	0.38

結果有三。其一，小人口的預測區間同時太寬且涵蓋不足，寬度與涵蓋率解耦。人數五萬時現行作法的區間寬達 5.401，而不可約下限僅 1.743，涵蓋率卻只有 0.38。寬度被灌水是因為 $\hat{\kappa}_t$ 含估計雜訊、使一階差變大而 $\hat{\sigma}$ 被高估；涵蓋失敗則因漂移項被壓平，使區間擺錯位置。換言之，小人口的問題是偏誤而非寬度，加寬區間無濟於事。此一結果限定了文獻長期以來「LC 模型預測區間過窄」的診斷在小人口的適用性。

其二，拔靴法的參數不確定性幾乎沒有貢獻，有時甚至更糟。因為拔靴法是繞著已經偏掉的配適值重抽，能偵測到的偏誤有限——第伍節的偏誤校正實驗顯示其偵測比例約為七成，但代價是變異數加倍。

其三，修勻確實壓低區間寬度，而且代價隨人口增大而惡化。人數一千一百九十萬時變體 S 的寬度僅 0.529、涵蓋率降至 0.38，方向與直覺相反。這為 Basellini et al. (2023) 的疑慮提供了量化證據，亦即本文的議題二。

二、 σ 的估計：變異成分的分離

上一小節指出區間過寬的來源是 $\hat{\sigma}$ 被估計雜訊灌水。此一現象可寫成一個明確的形式：由 $\hat{\kappa}_t = \kappa_t + u_t$ 可得 $\text{Var}(\Delta\hat{\kappa}) \approx \sigma^2 + \text{Var}(\Delta u)$ ，亦即樸素的 $\text{sd}(\Delta\hat{\kappa})$ 同時含有真實的年際變動與估計雜訊兩個成分。要取得前者，須把兩者分離。

直接的作法是以拔靴法估計 $\text{Var}(\Delta u^*)$ 後相減，但兩個大噪音量相減並不穩定，是動差法去偏的典型病症。本文改以狀態空間表述，令觀測方程為 $\hat{\kappa}_t = \kappa_t + u_t$ 、 $u_t \sim N(0, \tau_t^2)$ ，狀態方程為 $\kappa_t = \kappa_{t-1} + \delta + \varepsilon_t$ 、 $\varepsilon_t \sim N(0, \sigma^2)$ 。此一表述有兩項優勢。其一， τ_t^2 不必估計，給定年齡參數後 κ_t 的 Fisher 資訊為 $\sum_x \hat{\mu}_{x,t} \hat{\beta}_x^2$ ，而這一項正是卜瓦松 LC 迭代中 κ 更新式的分母，故取得它沒有額外成本。其二， σ^2 是在概似中被估計出來的，而非兩個估計量相減的餘數，結構上不可能為負，動差法的病症自動消失。變異成分的估計採第貳節所述的 REML，因為最大概似在估計變異成分時未扣除估計固定效果所消耗的自由度，會系統性低估。

表 24 σ 的三種估計方式 (真值 0.6791, 重複 100 次)

N	方法	中位數	偏誤	IQR	可行率
5×10^4	sd($\Delta\hat{\kappa}$) (現行)	1.4950	+0.8158	0.896	1.00
	狀態空間 ML	0.4029	-0.2763	0.429	1.00
	狀態空間 REML	0.5753	-0.1039	0.357	1.00
2×10^5	sd($\Delta\hat{\kappa}$)	1.0054	+0.3263	0.282	1.00
	狀態空間 ML	0.5392	-0.1400	0.172	1.00
	狀態空間 REML	0.5970	-0.0822	0.194	1.00
10^6	sd($\Delta\hat{\kappa}$)	0.7536	+0.0745	0.122	1.00
	狀態空間 ML	0.6318	-0.0473	0.107	1.00
	狀態空間 REML	0.6551	-0.0240	0.111	1.00

表 24 以真值 0.6791 為基準。樸素估計量在人數五萬時的中位數為 1.4950，偏誤高達 +0.82，即被灌水超過一倍；狀態空間 REML 為 0.5753，偏誤 -0.10，四分位距亦由 0.896 降至 0.357。最大概似版本則如理論所預期向下偏誤較大 (-0.28)，在三個規模下皆劣於 REML，故本文採用 REML。須注意三種方法在人數一百萬時的差距已大幅縮小，樸素估計量的偏誤降至 +0.07，亦即變異成分分離的必要性隨人口規模下降。

三、初始值的不確定性

σ 校正之後，寬度的問題大致解決，但位置的問題仍在。第參節已指出漂移項是偏誤主導，而預測的起點 $\hat{\kappa}_T$ 是單一年份的估計值，其誤差不隨配適期長度縮小。狀態空間表述在此提供了一項現成的資源：Kalman 濾波在最後一點給出的不只是 $\kappa_{T|T}$ ，還有它的變異數 P_T ，把後者納入預測分布即可反映初始值本身的不確定性。

表 25 變異成分分離與初始值不確定性對預測區間的影響 ($h = 10$ 、名目 80%、重複 100 次)

N	變體	寬度	涵蓋率
5×10^4	O 不可約下限 (參數已知)	2.093	0.74
	P 現行作法 (SVD 插入式)	8.949	0.27
	R 卜瓦松 + 狀態空間 REML	1.610	0.47
	RK R + Kalman 初始值變異數	1.707	0.54
2×10^5	O	2.106	0.82
	P	7.616	0.64
	R	1.860	0.72
	RK	1.901	0.72
10^6	O	2.103	0.80
	P	6.681	0.93
	R	2.025	0.77
	RK	2.019	0.77

表 25 的結果可分三點讀。其一，現行作法的失效在此再次確認，人數五萬時寬度 8.949 為不可約下限 2.093 的 4.3 倍，涵蓋率卻只有 0.27。其二，以卜瓦松配適搭配狀態

空間 REML 之後，寬度由 8.949 降至 1.610、涵蓋率由 0.27 升至 0.47；人數二十萬時由 7.616 與 0.64 變為 1.860 與 0.72，人數一百萬時則為 2.025 與 0.77，已與不可約下限的 2.103 與 0.80 十分接近。須指出人數五萬時的 1.610 已低於下限 2.093，亦即 REML 在該規模略為低估 σ ，區間反而稍窄，這與表 24 的 -0.10 偏誤一致。其三，加計初始值變異數 P_T 在小人口有效而在大人口無效：人數五萬時涵蓋率由 0.47 升至 0.54、寬度僅增加 6%，人數二十萬與一百萬時則幾無變化。這符合預期，因為 P_T 的大小取決於 $\hat{\kappa}_T$ 的估計精度，人口愈大精度愈高，該項的貢獻自然愈小。

須誠實指出殘餘的缺口。人數五萬時涵蓋率仍只有 0.54，距名目的 0.80 尚遠，而寬度已貼合下限，因此缺口不在寬度而在位置，亦即漂移項的偏誤。這一點無法由區間方法解決，須回到第伍節的點估計。

四、兩步校正

綜合前述，小人口區間的兩個病灶可分別處理：位置由漂移項的偏誤造成，寬度由 $\hat{\sigma}$ 的灌水造成。

表 26 SVD 與卜瓦松最大概似的漂移項估計（真值 -0.3678 ）

N	SVD 的漂移項	卜瓦松 MLE 的漂移項
50,000	-0.032 (偏誤 $+0.336$)	-0.377 (偏誤 -0.010)
200,000	-0.194 (偏誤 $+0.174$)	-0.369 (偏誤 -0.002)
1,000,000	-0.365	-0.367

表 26 顯示漂移項衰減並非小人口的固有性質，而是 SVD 對 $\log(D/E)$ 做最小平方所產生的結果。人數五萬時 SVD 估得 -0.032 、偏誤 $+0.336$ ，卜瓦松最大概似則為 -0.377 、偏誤僅 -0.010 。卜瓦松架構不取對數，衰減即告消失。此一發現獨立支持了 Basellini et al. (2023)「換到卜瓦松架構後第二階段調整不再必要」的論點，並把理由由「配適總死亡數依照模型假設成立」推進到「第一階段的估計本身即無偏」。

表 27 校正前後的預測區間寬度與涵蓋率（名目 80%）

N	方法	區間寬度	涵蓋率
200,000	oracle	1.743	0.81
	現行作法	5.081	0.75
	本文校正版	1.724	0.63
1,000,000	oracle	1.726	0.85
	現行作法	4.667	0.95
	本文校正版	1.721	0.83
11,900,000	oracle	1.712	0.78
	現行作法	2.033	0.82
	本文校正版	1.678	0.77

兩步合併之後的結果見表 27。本文的實務建議因此是：小人口的預測區間應以卜瓦松最大概似取代 SVD 以校正位置，並以狀態空間 REML 取代樸素的 $\text{sd}(\Delta\hat{\kappa})$ 以校正寬

度，人數十萬以下時再加計 Kalman 濾波的初始值變異數。三者皆無調校參數，計算成本亦可忽略—— σ 的估計是 23 維三對角矩陣上的一維最佳化，較動差法所需的多次完整配適快上兩到三個數量級。

七、 結論與後續工作

一、回到鄉鎮市區生命表的問題

本文開頭的問題是，368 個鄉鎮市區中有八成單一性別不足五萬人，這些地區能否編製生命表。依前述結果，答案不是單一的人口門檻，而須依參數分別回答，且判斷所需的量都可由資料事前計算。

α_x 在任何規模下都可估，但零格集中的年齡必須以 Firth 偏誤減少處理。此一結論沒有條件限制：Firth 在人數一萬時把 5 至 9 歲組的偏誤由標準 LC 的 +2.33、卜瓦松最大概似的 -13.03 降為 +0.43，在人數二十萬時亦不劣於卜瓦松，且無效率代價與調校參數。判斷是否需要它，只須看第一項診斷的最小單年死亡數中位數是否低於 5。

β_x 則有明確的可估性界限，其位置由第四項診斷的比值給出。比值低於 0.6 時不應以 SVD 估計，人數一萬（比值 0.43）的模擬中五種估計量的相關係數全在 0.125 以下即為明證；比值介於 0.6 與 1.2 之間是方法選擇效益最大的區間，人數五萬時標準 LC 的相關係數 0.040 與隨機方向無異，而 Firth 加 Fay-Herriot 收縮可達 0.542；比值超過 2 之後各方法趨於一致，SVD 亦可使用。須強調此一界限隨配適期長度移動，本文第肆節的二因子結果顯示配適期十五年以下時，任何人口規模都難以達到可用的精度。

漂移項的偏誤則與零格無關，須以資訊加權處理。卜瓦松最大概似在人數五萬時的漂移項偏誤為 0.0232，標準 LC 為 0.3144，相差十三倍；若必須留在高斯架構，以配適期望死亡數加權的 SVD 亦可將其降至 0.1223。

表 28 依事前診斷決定的估計策略（配適期 24 年）

診斷④比值	約當人口	α_x 與漂移項	β_x
< 0.6	2 萬以下	Firth 卜瓦松 (必要, 非選配); 診斷①的最小死亡中位數低於 5 時尤然	不予估計; 估出的方向與隨機向量無法區分
0.6 ~ 1.2	2 萬 ~ 20 萬	Firth 卜瓦松; 方法選擇的效益在此最大	卜瓦松或 Firth 搭配 Fay-Herriot 收縮; 相關係數可由 0.04 提升至 0.54
1.2 ~ 2	20 萬 ~ 50 萬	卜瓦松最大概似即可	卜瓦松或以 $\hat{\mu}$ 加權的 SVD, 加 Fay-Herriot 收縮
> 2	50 萬以上	各方法差異已小, SVD 亦可	各方法差異已小; HeteroPCA 於此亦有效

預測區間的建議則不分規模：以卜瓦松最大概似取代 SVD 校正位置，以狀態空間 REML 取代樸素估計校正寬度，人數十萬以下時再加計初始值變異數。惟須誠實指出，

即便如此處理，人數五萬時的涵蓋率仍只有 0.54，殘餘缺口在漂移項本身，故該規模的區間宜視為參考而非正式推論的依據。

二、研究限制

第一，本文所有的「小人口」皆由全國資料模擬而來，隱含小區域與全國有相同年齡型態的假設。真實鄉鎮市區的型態可能本就不同，此時前三項診斷仍然有效（它們只描述資料本身），但第四項診斷的最大奇異值會同時反映型態差異與噪音，解釋須更為謹慎。以真實縣市或鄉鎮市區資料驗證，是本文尚未完成的一步。

第二，第四項診斷的理論依據建立在白噪音之上，而本文的噪音是異質的，此處以 $\sqrt{1/\hat{\mu}}$ 作為等效尺度乃是近似。門檻的落點與門檻以上的還原程度都與實測吻合，但嚴格而言需補一組白化後的對照。

第三，重複次數為 100 次，第五之一小節的階梯分解為 400 次。由第伍節兩次獨立模擬的比較可知，重複 100 次時 α 偏誤的蒙地卡羅誤差約一成、 β 平方誤差和約兩成，解讀表中數值時應以此為精度參考。涵蓋率的精度更低，其標準誤約為 0.04。

第四，本文的模擬以卜瓦松生成死亡數，因此過度離散的效應在設計上即不存在，負二項或準概似方法的效益無從測得，須以真實資料檢驗。

第五，Fay-Herriot 收縮假設各年齡的 β_x 可交換，但真實的 β_x 有明確的年齡結構。目前結果顯示此一假設仍足以改善估計，更貼切的作法需引入相鄰年齡的相關性，等價於回到差分懲罰。

三、後續工作

本文第伍節之五已把損失函數納入比較，並劃出穩健損失的作用範圍。順此結果，下一步是把該範圍再推廣一層。中位數只是 $\tau = 0.5$ 的特例，若掃描 $\tau \in (0, 1)$ ，則最適的 τ 應略高於 0.5——因為零格替代造成的扭曲是單邊的，偏向左尾——且該偏移量應隨零格比例上升而增大。此一預測與崩潰點的論證同源，若成立即可把「 τ 該取多少」也接回可事前計算的診斷^②。另一條可微的路徑是 expectile (Newey and Powell 1987 的非對稱最小平方) 與 Huber M -估計量，兩者皆可微，因而能直接套進本文既有的區塊座標下降架構而不必另寫線性規劃，使檢查函數與平方損失之間的連續內插可在同一張圖上掃描。

其次是加權的檢查函數。若上述預測成立，自然的下一步是把資訊加權與檢查函數合併，同時具備對左尾扭曲的穩健性與 Wilmoth (1993) 所主張的資訊加權。本文第伍節已分別證明兩者各自有效，把它們合起來是順理成章的一步。

第三是以真實的縣市與鄉鎮市區資料驗證四項診斷。本文的門檻皆由模擬得出，而診斷的價值正在於使用者能在自己的資料上計算；若能在若干真實小區域上比對診斷的判讀與實際估計結果，本文的主張才算完整。

A 懲罰式估計的實作細節

本附錄保留懲罰式 Lee-Carter 模型的模型設定、演算法，以及其餘變體的比較。正文第肆節只取其中與「在高斯架構內修補的限度」直接相關的結果，其餘細節列於此處，以便日後需要時取用。

一、模型設定

在卜瓦松架構下加入 β_x 的懲罰項：

$$\min_{\alpha, \beta, \kappa} -\ell(\alpha, \beta, \kappa) + \lambda \sum_x w_x \left[a |\beta_x - \beta_{0x}| + \frac{1-a}{2} (\beta_x - \beta_{0x})^2 \right], \quad \text{s.t.} \quad \sum_x \beta_x = 1, \quad \sum_t \kappa_t = 0, \quad (5)$$

其中 $a = 1$ 為 LASSO、 $a = 0$ 為 Ridge、 $0 < a < 1$ 為 Elastic Net； w_x 為年齡別權重（可取 1 或自適應權重 $1/\sqrt{D_x}$ ，後者對應 Zou (2006) 的 adaptive LASSO）； β_0 為收縮目標。

二、演算法與收斂性

本文以區塊座標下降（Block Coordinate Descent）求解： α 有封閉解， κ 以 Newton 法更新後置中， β 則以 proximal Newton（二次近似加近端算子）更新——給定 Lagrange 乘子 ν ，各年齡的解為

$$\beta_x = \beta_{0x} + \frac{S(W_x(\tilde{\beta}_x - \beta_{0x}) - \nu, \lambda a w_x)}{W_x + \lambda(1-a)w_x}, \quad (6)$$

其中 $S(z, \gamma) = \text{sign}(z) \max(|z| - \gamma, 0)$ 為軟閾值算子， $W_x = \sum_t \hat{\mu}_{xt} \kappa_t^2$ 為負二階導， ν 以二分法求解使 $\sum_x \beta_x = 1$ 。每步並以步長折半確保目標函數不下降。

由於不可微的懲罰項僅作用於 β 這一個區塊、且在各年齡間可分離（separable），Tseng (2001) 關於區塊座標下降的收斂定理適用，可保證每個聚點皆為駐點。實測結果（表 29、圖 4）顯示：目標函數單調上升， $\log_{10} \max_x |\Delta \beta_x|$ 隨迭代次數線性下降，即幾何收斂；且懲罰強度越大收斂越快（ $\lambda = 0$ 需 33 次、 $\lambda = 10^3$ 需 18 次、 $\lambda = 10^4$ 僅需 6 次），因為懲罰項改善了 Hessian 的條件數。

表 29 迭代收斂情形（女性 2001~2024 年， $\tau = 10^{-11}$ ）

λ	迭代次數	收斂	最終 $\max_x \Delta \beta_x $
0	33	是	8.0×10^{-6}
10^3	18	是	1.2×10^{-5}
10^4	6	是	5.9×10^{-7}




图 4 迭代收斂診斷。左：目標函數與最終值的間隙（對數尺度）；右：參數變動量。兩者皆呈線性下降，即幾何收斂。

三、Elastic Net 的其他變體

由於前一小節顯示 LASSO 的弱點在偏誤，本文另外試驗三種以「降低收縮偏誤」為目的的變體，並與 LASSO、Elastic Net 並列（表 30）：

- **自適應 LASSO** (Zou 2006)：以未懲罰估計的偏離量倒數為權重， $w_x = 1/|\hat{\beta}_x^{\text{unpen}} - \beta_{0x}|$ ，使證據較強的年齡組受到較輕的懲罰。
- **鬆弛 LASSO** (Meinshausen 2007)：先以 LASSO 選出作用集，再於作用集上不加懲罰重新配適，非作用集固定於 β_0 。
- **MCP** (Zhang 2010)：非凸懲罰，其導數隨 $|\beta_x - \beta_{0x}|$ 增大而遞減至零，因而保留稀疏性卻不對大係數施加偏誤。

表 30 Elastic Net 族各變體的比較 ($N = 20$ 萬，重複 100 次，各取其最適 λ)

方法	最適 $\lambda/\lambda_{\max}$	偏誤 ²	變異數	MSE
Ridge (前表)	0.003	0.00270	0.00311	0.00578
LASSO	0.03	0.00219	0.00484	0.00698
MCP ($\gamma = 3$)	0.03	0.00219	0.00485	0.00698
Elastic Net	0.10	0.00463	0.00255	0.00716
自適應 LASSO	0.40	0.00313	0.00532	0.00840
鬆弛 LASSO	0.20	0.00734	0.00192	0.00924

三項觀察。其一，沒有任何一個稀疏型變體能勝過單純的 Ridge。這與前一小節的診斷一致：真值 β_x 並無恰等於 $1/A$ 者，問題本質是稠密的，因此所有為稀疏性設計的機制都無從發揮。其二，MCP 與 LASSO 幾乎完全相同（MSE 差異在第四位小數）。原因是在最適的 λ 之下閾值本就很小，MCP「對大係數不加偏誤」的區段極少被觸發，退化為 LASSO。其三，鬆弛 LASSO 的變異數最低卻 MSE 最差——它把非作用集硬性固定於 β_0 ，等於施加一個過強的等式限制，偏誤平方因而升至 0.0073。

四、點估計 LASSO 與分位數 LASSO 的演算法差異

本文在兩處用到 L_1 懲罰，但兩者的最佳化結構並不相同，可用的演算法也不相同。此一區分在文獻中常被「LASSO」一詞掩蓋，卻直接決定了實作的可行性，故於此釐清。

(一) 兩種問題的結構

點估計 LASSO (本文第柒節所用) 以平滑的損失搭配 L_1 懲罰：

$$\min_{\beta} \underbrace{-\ell(\beta)}_{\text{可微}} + \underbrace{\lambda \sum_x w_x |\beta_x - \beta_{0x}|}_{\text{不可微，但逐座標可分離}}. \quad (7)$$

分位數 LASSO (即第肆節所述 Rabbi and Mazzuco 的二維修勻) 則以檢查函數 $\rho_{\tau}(u) = u(\tau - \mathbf{1}\{u < 0\})$ 為損失：

$$\min_z \underbrace{\sum_i \rho_{\tau}(y_i - (Mz)_i)}_{\text{不可微，且耦合所有座標}} + \lambda \|Dz\|_{L_1}. \quad (8)$$

兩者的關鍵差別在於不可微的部分落在哪裡。式 (7) 的不可微項是懲罰，逐座標分離；式 (8) 的不可微項是損失本身，而 $\rho_{\tau}(y_i - (Mz)_i)$ 把所有座標耦合在內積 $(Mz)_i$ 之中，無法分離。

(二) Tseng (2001) 的條件與其違反

Tseng (2001) 的收斂定理要求目標函式可寫成

$$f(x_1, \dots, x_N) = f_0(x_1, \dots, x_N) + \sum_{k=1}^N f_k(x_k), \quad (9)$$

其中 f_0 可微、不可微的 f_k 逐區塊可分離。該文並明白指出：

「若 f 不可微，座標下降法可能卡在非駐點，即使 f 為凸……因此一般認為該方法不適用於不可微的情形。惟當 f 的不可微部分可分離時則為例外。」(Tseng 2001: 475, 本文中譯)

對照可知：式 (7) 符合式 (9) 的形式，故第柒節之三的區塊座標下降有收斂保證；式 (8) 則不符合，座標下降並無保證。

(三) 以實際資料驗證卡滯

上述為理論陳述，本文另以實際資料檢驗其是否真的發生。取女性 2015~2024 年 ($22 \times 10 = 220$ 格) 建構修勻問題，對同一個目標函式式 (8) 施以兩種演算法，結果如表 31。

為避免「卡滯只是步長設定不良」的疑慮，此處的座標下降採用 **精確的單座標最小化**—— L_1 損失沿單一座標的最小值為加權中位數，有封閉解，不涉及任何步長選擇。

表 31 同一目標函式下兩種演算法的比較（女性 2015~2024 年）

目標函式	演算法	目標值	是否達最適	診斷
分位數 LASSO	線性規劃（內點法）	30.02	是	—
分位數 LASSO	座標下降（精確）	1244.20	否	可改善的單座標移動 0/220
點估計 LASSO	座標下降（軟閾值）	—	是	KKT 最大違反 7.1×10^{-16}

座標下降在**第一次掃描後即停止**，且目標值等於起始值——換言之完全沒有移動，而該點的目標值是線性規劃解的 **41.4 倍**。

卡滯的機制可以明確指認。在起始點 $z = \mathbf{0}$ 處，沿第 j 個座標移動時，保真列貢獻權重 1、懲罰列貢獻權重 $\sum |D_{.j}|$ ；本設定下後者的中位數為 21.60、最小值 5.40，**全部 220 個座標的懲罰權重都大於保真權重**。由於 L_1 的單座標最小值為加權中位數，權重集中於「不動」的一側時最小值即為 0，故**每個座標都同意不要移動**。然而聯合移動可使目標值由 1244.20 降至 30.02——此即典型的「對角山谷」：沿任一軸皆上坡，沿對角線則下坡。本文逐一檢驗 220 個座標的八種位移，確認**無任何單座標移動可改善**，證實此為結構性的卡滯而非實作缺陷。

對照之下，同一組資料改用平方損失搭配 L_1 懲罰，座標下降 **兩次掃描即收斂**，KKT 條件的最大違反為 7.1×10^{-16} ，確實達到最適。**兩者的差別純粹來自損失函數是否可微**。

（四）對本文實作的意涵

上述分析解釋了本文兩個模組為何採用不同的演算法，且此一選擇是 **結構決定的**，而非實作偏好：

表 32 本文兩個模組的目標函式與演算法

模組	目標函式	演算法
smooth_l1_2d()	L_1 損失 + L_1 懲罰	rq.fit.sfn (Frisch–Newton 內點法)
lc_penalized()	卜瓦松對數概似 + L_1 懲罰	proximal Newton + 軟閾值

三項延伸意涵值得記錄。

其一，**第柒節之三的收斂論證因此有了對照組**。該處主張「不可微的懲罰項僅作用於 β 這一個區塊、且在各年齡間可分離，故 Tseng (2001) 的定理適用」；表 31 顯示，若把損失換成 L_1 ，同一套演算法便會失效。此一對照使該主張不再只是引用定理，而有了具體的反面證據。

其二， L_1 損失的選擇有其統計理由，非僅為計算方便。 $\tau = 0.5$ 的檢查函數等價於 Laplace 分配的最大概似，對離群值較平方損失穩健；Schuette (1978) 即以此為由

主張以線性規劃處理修勻問題，Dokumentov et al. (2018) 沿用之，Rabbi and Mazzucco (2021) 亦引述此點。換言之，穩健性與「必須使用線性規劃」是同一個選擇的兩面。

其三，解的性質不同。線性規劃的解落在可行域的頂點上，意味著恰有若干筆殘差為零（曲面「內插」這些觀測值）；平方損失的解則一般不內插任何一點。此一差異在解釋修勻後曲面的行為時須留意，亦是 L_1 修勻「較不平滑但誤差較小」（表 7）的成因之一。

B 懲罰前後 β_x 的逐年齡比較

本附錄逐年齡呈現加懲罰與不加懲罰的 β_x 估計值差異。

一、實際資料

表 33 為女性 2001~2024 年的估計結果（LASSO 與 Elastic Net 取 $\lambda/\lambda_{\max} = 0.10$ 、Ridge 取 0.003）。虛線水準 $1/A = 0.0455$ 為收縮目標。

表 33 各年齡組的 β_x 估計值（女性 2001~2024 年）

年齡組	未懲罰	LASSO	Elastic Net	Ridge	LASSO – 未懲罰	Ridge – 未懲罰	併入 $1/A$
0	0.0496	0.0455	0.0455	0.0502	-0.0042	+0.0005	是
1-4	0.1066	0.0455	0.0611	0.0661	-0.0612	-0.0406	是
5-9	0.0698	0.0455	0.0455	0.0540	-0.0243	-0.0158	是
10-14	0.0443	0.0455	0.0455	0.0485	+0.0012	+0.0042	是
15-19	0.0578	0.0455	0.0455	0.0531	-0.0124	-0.0047	是
20-24	0.0440	0.0455	0.0455	0.0473	+0.0015	+0.0032	是
25-29	0.0484	0.0455	0.0455	0.0494	-0.0029	+0.0010	是
30-34	0.0453	0.0455	0.0455	0.0474	+0.0002	+0.0021	是
35-39	0.0394	0.0455	0.0455	0.0428	+0.0061	+0.0034	是
40-44	0.0328	0.0455	0.0455	0.0368	+0.0127	+0.0040	是
45-49	0.0261	0.0387	0.0341	0.0302	+0.0126	+0.0042	
50-54	0.0290	0.0389	0.0348	0.0321	+0.0100	+0.0031	
55-59	0.0442	0.0455	0.0455	0.0457	+0.0013	+0.0015	是
60-64	0.0561	0.0546	0.0570	0.0568	-0.0015	+0.0006	
65-69	0.0686	0.0687	0.0691	0.0689	+0.0001	+0.0003	
70-74	0.0668	0.0675	0.0674	0.0675	+0.0006	+0.0006	
75-79	0.0528	0.0531	0.0537	0.0537	+0.0004	+0.0010	
80-84	0.0439	0.0455	0.0455	0.0451	+0.0016	+0.0012	是
85-89	0.0319	0.0357	0.0333	0.0333	+0.0038	+0.0014	
90-94	0.0215	0.0264	0.0224	0.0236	+0.0049	+0.0022	
95-99	0.0135	0.0255	0.0197	0.0194	+0.0121	+0.0059	
100+	0.0078	0.0455	0.0422	0.0284	+0.0376	+0.0206	是

值得注意的是，1-4 歲的未懲罰估計值最大 (0.1066) 卻被完全併入 $1/A$ 。這並非矛盾：LASSO 的軟閾值為 $\lambda w_x/W_x$ ，而 $W_x = \sum_t \hat{\mu}_{xt} \kappa_t^2$ 正是該年齡的資訊量。幼兒死亡數極少使 W_x 很小，因此其估計值雖大卻不精確，反而受到最重的懲罰。懲罰的強弱取決於資訊量而非係數大小，此點與一般迴歸中 LASSO 的行為一致，但在死亡率模型上格外明顯。

存活下來（未被併入 $1/A$ ）的是 45-54 歲與 60-99 歲，亦即高齡段的改善型態確實顯著偏離平均，這與人口學的認知相符。




圖 5 懲罰前後 β_x 的逐年齡比較。左上為實際資料；右上與左下為模擬的平均估計值（含真值）；右下為逐年齡的標準差。

二、模擬（已知真值）

在模擬中可進一步把差異拆成偏誤與標準差（表 34）。 $N = 5$ 萬、 $\lambda/\lambda_{\max} = 0.20$ 時，未懲罰版的平均絕對偏誤為 0.0069、平均標準差 0.0679；LASSO 則為 0.0123 與 0.0078。亦即標準差的中位數降幅達 75%，與絕對偏誤增為 1.8 倍之間取得平衡。

表 34 偏誤最大的五個年齡組（模擬， $N = 5$ 萬，重複 100 次）

年齡組	真值	未懲罰平均	LASSO 平均	LASSO 偏誤	未懲罰 SD	LASSO SD
1-4	0.1107	0.1107	0.0461	-0.0646	0.1666	0.0060
100+	0.0058	-0.0012	0.0455	+0.0397	0.1008	0.0075
5-9	0.0785	0.0924	0.0455	-0.0330	0.1899	0.0000
95-99	0.0127	0.0078	0.0366	+0.0239	0.0288	0.0123
45-49	0.0260	0.0286	0.0417	+0.0157	0.0321	0.0097

懲罰造成的偏誤集中在兩端年齡（1-9 歲與 95 歲以上），正是資訊量最稀薄之處；而這些年齡的未懲罰標準差高達 0.10 至 0.19，本就不具參考價值。換言之，懲罰在這些年齡是以「明確的偏誤」取代「無法使用的變異」，是否值得須視用途而定：若後續要計算平均餘命（對 β_x 的加權以死亡數為主），兩端年齡的偏誤影響有限；若要直接解讀各年齡的改善速度，則須特別註明。

參考文獻

一、中文部分

- 王信忠、金碩、余清祥(2012)。小區域死亡率推估之研究。人口學刊, 45: 121-154。doi:10.6191/JPS.2012.11
- 王信忠、余清祥、王子瑜 (2017)。臺灣原住民死亡率暨生命表編撰研究。人口學刊, 55: 99-131。doi:10.6191/JPS.2017.55.03
- 余清祥、王信忠、陳譽騰 (2021)。年輪變動比用於小區域人口推估的探討。人口學刊, 63: 99-133。doi:10.6191/JPS.202112_(63).0003
- 余清祥、王信忠、呂靖翎 (2025)。平均餘命與標準化死亡率之相關分析。人口學刊, 85-116。
- 陳政勳、余清祥 (2010)。小區域人口推估研究：臺北市、雲嘉兩縣、澎湖縣的實證分析。人口學刊, 41: 153-183。doi:10.6191/JPS.2010.9

二、英文部分

- Alho, J. M. 1992. "Modeling and Forecasting U.S. Mortality: Comment." *Journal of the American Statistical Association* 87(419): 673-674.
- Basellini, U., C. G. Camarda, and H. Booth. 2023. "Thirty Years On: A Review of the Lee-Carter Method for Forecasting Mortality." *International Journal of Forecasting* 39(3): 1033-1049.
- Booth, H., J. Maindonald, and L. Smith. 2002. "Applying Lee-Carter under Conditions of Variable Mortality Decline." *Population Studies* 56(3): 325-336.
- Booth, H., R. J. Hyndman, L. Tickle, and P. De Jong. 2006. "Lee-Carter Mortality Forecasting: A Multi-country Comparison of Variants and Extensions." *Demographic Research* 15: 289-310.
- Booth, H., L. Tickle, and L. Smith. 2005. "Evaluation of the Variants of the Lee-Carter Method of Forecasting Mortality: A Multi-country Comparison." *New Zealand Population Review* 31(1): 13-34.
- Brouhns, N., M. Denuit, and J. K. Vermunt. 2002. "A Poisson Log-bilinear Regression Approach to the Construction of Projected Lifetables." *Insurance: Mathematics and Economics* 31(3): 373-393.
- Bühlmann, P., and S. van de Geer. 2011. *Statistics for High-Dimensional Data: Methods, Theory and Applications*. Springer.
- Cairns, A. J. G., D. Blake, K. Dowd, G. D. Coughlan, and M. Khalaf-Allah. 2011. "Bayesian Stochastic Mortality Modelling for Two Populations." *ASTIN Bulletin* 41(1): 29-59.
- Camarda, C. G., and U. Basellini. 2021. "Smoothing, Decomposing and Forecasting Mortality Rates." *European Journal of Population* 37(3): 569-602.
- Chen, L., A. J. G. Cairns, and T. Kleinow. 2017. "Small Population Bias and Sampling Effects in Stochastic Mortality Modelling." *European Actuarial Journal* 7(1): 193-230.
- Currie, I. D. 2011. "Modelling and Forecasting the Mortality of the Very Old." *ASTIN Bulletin* 41(2): 419-427.

- Currie, I. D. 2013. "Smoothing Constrained Generalized Linear Models with an Application to the Lee-Carter Model." *Scandinavian Actuarial Journal* 2016(4): 356-383.
- Currie, I. D., M. Durban, and P. H. C. Eilers. 2004. "Smoothing and Forecasting Mortality Rates." *Statistical Modelling* 4(4): 279-298.
- Delwarde, A., M. Denuit, and P. Eilers. 2007. "Smoothing the Lee-Carter and Poisson Log-bilinear Models for Mortality Forecasting: A Penalized Log-likelihood Approach." *Statistical Modelling* 7(1): 29-48.
- Djeundje, V. A. B., and I. D. Currie. 2010. "Smoothing Dispersed Counts with Applications to Mortality Data." *Annals of Actuarial Science* 5(1): 33-52.
- Dokumentov, A., R. J. Hyndman, and L. Tickle. 2018. "Bivariate Smoothing of Mortality Surfaces with Zero Counts: The Lasso2d Method." *Stat* 7(1): e199.
- Eilers, P. H. C., and B. D. Marx. 1996. "Flexible Smoothing with B-splines and Penalties." *Statistical Science* 11(2): 89-102.
- Friedman, J., T. Hastie, and R. Tibshirani. 2010. "Regularization Paths for Generalized Linear Models via Coordinate Descent." *Journal of Statistical Software* 33(1): 1-22.
- Hoerl, A. E., and R. W. Kennard. 1970. "Ridge Regression: Biased Estimation for Nonorthogonal Problems." *Technometrics* 12(1): 55-67.
- Hunt, A., and D. Blake. 2020. "Identifiability in Age/Period Mortality Models." *Annals of Actuarial Science* 14(2): 461-499.
- Hunt, A., and D. Blake. 2021. "On the Structure and Classification of Mortality Models." *North American Actuarial Journal* 25(sup1): S215-S234.
- Hyndman, R. J., and M. S. Ullah. 2007. "Robust Forecasting of Mortality and Fertility Rates: A Functional Data Approach." *Computational Statistics & Data Analysis* 51(10): 4942-4956.
- James, W., and C. Stein. 1961. "Estimation with Quadratic Loss." *Proceedings of the Fourth Berkeley Symposium on Mathematical Statistics and Probability* 1: 361-379.
- Lee, R. D., and L. R. Carter. 1992. "Modeling and Forecasting U.S. Mortality." *Journal of the American Statistical Association* 87(419): 659-671.
- Lee, R., and T. Miller. 2001. "Evaluating the Performance of the Lee-Carter Method for Forecasting Mortality." *Demography* 38(4): 537-549.
- Jarner, S. F., and E. M. Kryger. 2011. "Modelling Adult Mortality in Small Populations: The SAINT Model." *ASTIN Bulletin* 41(2): 377-418.
- Lee, J. D., Y. Sun, and M. A. Saunders. 2014. "Proximal Newton-type Methods for Minimizing Composite Functions." *SIAM Journal on Optimization* 24(3): 1420-1443.
- Li, J. S.-H., M. R. Hardy, and K. S. Tan. 2009. "Uncertainty in Mortality Forecasting: An Extension to the Classical Lee-Carter Approach." *ASTIN Bulletin* 39(1): 137-164.
- Li, N., R. D. Lee, and S. Tuljapurkar. 2004. "Using the Lee-Carter Method to Forecast Mortality for Populations with Limited Data." *International Statistical Review* 72(1): 19-36.

- Li, N., and R. Lee. 2005. "Coherent Mortality Forecasts for a Group of Populations: An Extension of the Lee-Carter Method." *Demography* 42(3): 575-594.
- Lu, Y., and D. Zhu. 2023. "Modelling Mortality: A Bayesian Factor-augmented VAR (FAVAR) Approach." *ASTIN Bulletin* 53(1): 29-61.
- Meinshausen, N. 2007. "Relaxed Lasso." *Computational Statistics & Data Analysis* 52(1): 374-393.
- Pitt, D., J. Li, and T. K. Lim. 2018. "Smoothing Poisson Common Factor Model for Projecting Mortality Jointly for Both Sexes." *ASTIN Bulletin: The Journal of the IAA* 48(2): 509-541.
- Rabbi, A. M. F., and S. Mazzucco. 2021. "Mortality Forecasting with the Lee-Carter Method: Adjusting for Smoothing and Lifespan Disparity." *European Journal of Population* 37(1): 97-120.
- Renshaw, A. E., and S. Haberman. 2003. "Lee-Carter Mortality Forecasting with Age-specific Enhancement." *Insurance: Mathematics and Economics* 33(2): 255-272.
- Santolino, M. 2020. "The Lee-Carter Quantile Mortality Model." *Scandinavian Actuarial Journal* 2020(7): 614-633.
- Schuette, D. R. 1978. "A Linear Programming Approach to Graduation." *Transactions of Society of Actuaries* 30: 407-431.
- Shang, H. L., H. Booth, and R. J. Hyndman. 2011. "Point and Interval Forecasts of Mortality Rates and Life Expectancy: A Comparison of Ten Principal Component Methods." *Demographic Research* 25: 173-214.
- Stoeldraijer, L., C. van Duin, L. van Wissen, and F. Janssen. 2018. "Comparing Strategies for Matching Mortality Forecasts to the Most Recently Observed Data." *Genus* 74(1): 16.
- Tibshirani, R. 1996. "Regression Shrinkage and Selection via the Lasso." *Journal of the Royal Statistical Society, Series B* 58(1): 267-288.
- Tseng, P. 2001. "Convergence of a Block Coordinate Descent Method for Nondifferentiable Minimization." *Journal of Optimization Theory and Applications* 109(3): 475-494.
- Wang, H. C., C. J. Yue, and C. T. Chong. 2018. "Mortality Models and Longevity Risk for Small Populations." *Insurance: Mathematics and Economics* 78: 351-359.
- Wilmoth, J. R. 1993. *Computational Methods for Fitting and Extrapolating the Lee-Carter Model of Mortality Change*. Technical Report, Department of Demography, University of California, Berkeley.
- Wiśniowski, A., P. W. F. Smith, J. Bijak, J. Raymer, and J. J. Forster. 2015. "Bayesian Population Forecasting: Extending the Lee-Carter Method." *Demography* 52(3): 1035-1059.
- Yang, S. S., J. C. Yue, and H. C. Huang. 2010. "Modeling Longevity Risks Using a Principal Component Approach: A Comparison with Existing Stochastic Mortality Models." *Insurance: Mathematics and Economics* 46(1): 254-270.
- Yue, J. C., H. C. Wang, and T. Y. Wang. 2019. "Using Graduation to Modify the Esti-

mation of Lee–Carter Model for Small Populations.” *North American Actuarial Journal*. doi:10.1080/10920277.2019.1650288

Zhang, L., and Y. Zhuang. 2026. “What KAN Mortality Say: Smooth and Interpretable Mortality Modeling Using Kolmogorov–Arnold Networks.” *ASTIN Bulletin* 56(1): 32-59.

Zhang, C.-H. 2010. “Nearly Unbiased Variable Selection under Minimax Concave Penalty.” *The Annals of Statistics* 38(2): 894-942.

Zou, H. 2006. “The Adaptive Lasso and Its Oracle Properties.” *Journal of the American Statistical Association* 101(476): 1418-1429.

Zou, H., and T. Hastie. 2005. “Regularization and Variable Selection via the Elastic Net.” *Journal of the Royal Statistical Society, Series B* 67(2): 301-320.